



雲南經濟管理學院  
YUNNAN COLLEGE OF BUSINESS MANAGEMENT

## 本科毕业论文（设计）

基于改进 EfficientNet 的番茄叶片病害识别

院 部： 信息与智能工程学院

姓 名： 郭兆国

学 号： 20221001714

专 业： 人工智能

年 级： 2022 级

指导教师： 杨云

职 称： 教授

完成日期： 2025 年 8 月

## 云南经济管理学院毕业论文（设计）原创性及知识产权声明

本人郑重声明：所呈交的论文（设计）是本人在指导教师的指导下独立进行研究所取得的成果。除了文中特别加以标注引用的内容外，本论文（设计）不包括任何其他人或集体已经发表或撰写的成果作品。本人完全意识到本声明的法律后果由本人承担

特此声明

毕业论文（设计）作者签名：

年 月 日

## 关于毕业论文（设计）使用和授权的说明

本毕业论文（设计）作者完全了解云南经济管理学院有关保留、使用毕业论文（设计）的规定，即：学校有权保留并向国家有关部门或机构送交毕业论文（设计）的复印件和电子版；允许毕业论文（设计）被查阅和借阅。本人授权云南经济管理学院可以将本毕业论文（设计）的全部内容或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本毕业论文（设计）。

毕业论文（设计）作者签名：

年 月 日

指导教师签名：

年 月 日

## 摘 要

目前在番茄叶片病害识别领域，存在资源受限场景下的高精度识别需求。为解决该需求，本文基于 EfficientNetB0 架构，提出了融合动态通道注意力（DCA）、可分离扩张卷积（SDC）和通道注意力（CAN）的改进模型 DSC-EfficientNetB0。本实验采用的数据集来源于 PlantVillage 数据库，包含 10 种番茄叶片病害疾病。在数据预处理阶段进行了数据平衡、增强、划分以及归一化等操作，并在后续实验训练中采用了迁移学习和混合精度训练策略。最终，对比实验展示出该模型准确率为 99.78%，参数量 4.26M，FLOPs 为 0.7974G，推理时间 2.53s。在准确率与损失曲线波动小、收敛快的良好状态下，既保持了高精度识别又明显地降低了计算资源，实现了精度与效率的良好平衡，远优于原版 EfficientNetB0、ResNet50、MobileNetV3Small 等主流模型。随后，消融实验与混淆矩阵证明了 DCA、SDC 和 CAN 的协同增效性。综上，该研究提出的模型兼顾了轻量化与高识别精度的需求，具备较高的部署可行性，为农业实地应用和边缘设备上的智能病害诊断监测提供了技术支持。

关键词：番茄叶片病害识别；EfficientNetB0；动态通道注意力；可分离扩张卷积；通道注意力；迁移学习；轻量化

## Abstract

In the current field of tomato leaf disease recognition, there is a demand for high-precision recognition in resource-constrained scenarios. To address this need, this study proposes an improved model named DSC-EfficientNetB0 based on the EfficientNetB0 architecture, which integrates Dynamic Channel Attention (DCA), Separable Dilated Convolution (SDC), and Channel Attention Network (CAN). The dataset used in this experiment is from the PlantVillage database, covering 10 types of tomato leaf diseases. In the data preprocessing stage, operations such as data balancing, augmentation, division, and normalization were performed. During the subsequent experimental training, transfer learning and mixed-precision training strategies were adopted. Finally, comparative experiments show that the model achieves an accuracy of 99.78%, with a parameter count of 4.26M, FLOPs of 0.7974G, and an inference time of 2.53s. It exhibits small fluctuations in accuracy and loss curves as well as fast convergence. While maintaining high-precision recognition, the model significantly reduces computational resources, achieving a good balance between accuracy and efficiency. It outperforms mainstream models such as the original EfficientNetB0, ResNet50, and MobileNetV3Small by a notable margin. Subsequently, ablation experiments and confusion matrices verify the synergistic effect of DCA, SDC, and CAN. In conclusion, the model proposed in this study meets the requirements of lightweight design and high recognition accuracy, has high deployment feasibility, and provides technical support for intelligent disease diagnosis and monitoring in agricultural field applications and on edge devices.

**Key words:** Tomato leaf disease identification; EfficientNetB0; Dynamic Channel Attention; Separable Dilated Convolution; Channel Attention; Transfer learning; Lightweight

# 目 录

摘 要 .....	I
<b>Abstract</b> .....	II
1 绪论 .....	1
1.1 研究背景和意义 .....	1
1.2 国内外研究现状 .....	2
1.3 研究内容 .....	4
1.4 技术路线 .....	4
1.5 论文结构 .....	6
2 相关理论知识 .....	7
2.1 卷积神经网络 .....	7
2.2 EfficientNet 网络概述 .....	8
2.6.1 复合缩放策略 .....	8
2.6.2 基础架构：MBConv 模块与 SE 注意力 .....	8
2.6.3 EfficientNetB0 概述 .....	10
2.3 混合精度训练 .....	11
2.4 迁移学习 .....	11
2.5 注意力机制 .....	11
3 数据集与预处理 .....	12
3.1 数据集 .....	12
3.2 数据预处理 .....	12
3.2.1 数据平衡与增强 .....	12
3.2.2 数据划分、泄露检测与归一化 .....	14
4 基于 DSC-EfficientNetB0 的番茄叶片病害识别模型 .....	15
4.1 DSC-EfficientNetB0 模型设计思路 .....	15
4.1.1 EfficientNetB0 作为主干网络的选择 .....	15

4.1.2 结构改进的必要性 .....	15
4.1.3 引入新模块 .....	15
4.2 DSC-EfficientNetB0 模型 .....	16
4.3 动态通道注意力（DCA） .....	18
4.3.1 动态通道注意力的原理及架构 .....	18
4.4 可分离扩张卷积（SDC） .....	20
4.4.1 可分离扩张卷积的原理及架构 .....	20
4.5 通道注意力（CAN） .....	22
4.5.1 通道注意力的原理及架构 .....	22
5 实验配置与结果分析 .....	24
5.1 实验设置及评价指标 .....	24
5.1.1 实验设置 .....	24
5.1.2 评价指标 .....	24
5.2 对比实验结果与分析 .....	24
5.3 消融实验结果与分析 .....	31
6 总结与展望 .....	37
6.1 总结 .....	37
6.2 展望 .....	37
参考文献 .....	39
致  谢 .....	41

# 1 绪论

## 1.1 研究背景和意义

“十四五”规划明确提出要保障粮食安全、推进农业现代化建设，并特别强调“藏粮于技”的科技兴农战略<sup>[1]</sup>。在此背景下，智慧农业成为了推动农业现代化发展的关键。

番茄作为重要的经济作物，它的稳定增产关乎粮食供给与农民增收，但在番茄种植过程中，病虫害因素一直是直接影响高质量增产的重要原因。然而，早期全靠专业的人员来检测番茄病害，农民和农技人员需要通过人眼观察进行诊断，这种方式不仅耗时费力，而且由于病害的多样性和早期症状的相似性，还经常容易出现误诊和漏诊。另外，由于人工检测通常依赖经验和感官判断，检测的准确率存在较大的波动，人工检测的难度大大增加。这类传统人工巡检模式不仅效率低下，还增加了大量成本，难以适应当下规模化的种植需求。

近年来，随着人工智能的快速发展，深度学习技术在病虫害识别中的应用逐渐成为焦点。特别是卷积神经网络（CNN），因其在图像识别领域的优异表现，已经成为农业病虫害检测的核心技术之一<sup>[2]</sup>。与传统人工检测相比，深度学习技术能够快速准确地识别不同种类的病害。有关研究表明，基于深度学习的番茄病害识别方法在识别准确率和时间节省上展现了突出优势<sup>[3]</sup>。尽管目前的深度学习技术在病害识别方面取得了成果，但现有的模型和方法仍存在一定的局限性，如采用 MobileNetV3 改进的模型实现 97.29% 识别准确率，但模型参数量却达到了 41.55MB，在树莓派等边缘设备推理耗时超 500ms，难以满足农业实时检测需求<sup>[4]</sup>。传统卷积神经网络（如 ResNet50、VGG16）虽然识别精度高达 99.02%，但参数量超 2500 万，计算量（FLOPs）超 10G，仅能在实验室环境运行，无法部署于无人机、手持终端等资源受限设备<sup>[5]</sup>。而在文献<sup>[6]</sup>中关于识别苹果病害叶片，虽然 EfficientNet 系列的原始版 EfficientNetB0 参数量达 537 万，但它具备混合缩放策略的特性，平衡了参数量与精度，本身综合性能就远超传统神经网络。

因此，本文聚焦“资源受限场景下的番茄叶片病害高精度识别”，借助高效卷积神经网络 EfficientNet 系列中的基础模型 EfficientNet-B0（简称 EfficientNetB0）更优秀的轻量高效特性，针对田间地头、温室大棚等场景对低功耗、实时性的需求，提出了改进 EfficientNetB0 模型的番茄叶片病害识别研究。研究目的在于通过结构轻量化、

关键特征提取，实现“轻量架构 + 高精度识别”的突破。让高精度检测不再依赖昂贵设施，普通手机和便携终端就能快速识别病害，帮助农户第一时间精准施策。

## 1.2 国内外研究现状

在智慧农业的发展过程中，基于深度学习的农作物病害识别技术逐渐成为保障农业生产连续稳定的关键支撑。随着卷积神经网络模型的迭代和图像采集技术的升级，国内外科研人员在这一领域持续投入了大量精力，从数据集构建到模型轻量化优化层层攻坚，已在玉米大斑病、番茄晚疫病等具体病害识别上取得一系列有实践价值的研究成果。

近三年的国内研究中，2022 年，牛学德等人<sup>[7]</sup>针对传统图像识别方法存在人工提取特征困难、识别耗时长和准确率低等问题，提出一种迁移学习与改进的 DensetNet 卷积神经网络相结合的模型，与 AlexNet 网络、VGG 网络+迁移学习和 MobileNet 网络+迁移学习 3 种深度卷积模型相比，识别精度更高，测试准确率达到 97.76%。2022 年，周巧黎等人<sup>[8]</sup>针对番茄病害的实时无损检测，提出一种迁移学习+基于改进轻量级卷积神经网络 MobileNetV3 的番茄叶片病害分类识别方法，平均测试的识别准确率 98.25%，模型的数据规模 43.57MB。2023 年，马丽等人<sup>[4]</sup>以轻量卷积神经网络 MobileNetV3 为基础模型进行改进，提出了 DM-MobileNetV3 模型，针对番茄叶片病斑的不易分类特征，主要从卷积层和损失函数两方面来改进，在 bottleneck 中引入空洞卷积和感知机层，并调整损失函数为 FocalLoss 函数，使模型的识别精度对比原 MobileNetV3、ResNet50 等提升了 2.13%，平均识别准确率达到 97.29%，模型大小 41.55MB。2023 年，李云红等人<sup>[9]</sup>针对番茄叶片病害识别方法存在丢失特征信息、易产生过拟合现象和各样本数据不均匀的问题，提出基于混合注意力机制的 DenseNet 的番茄叶片病害识别模型 AT-DsenseNet 模型，并运用迁移学习方法，在 6 种番茄叶片病害图像上进行测试，准确率达到 99.49%，模型大小 8.11MB。2023 年，王瑞鹏等人<sup>[6]</sup>针对苹果叶片病害识别中病害斑小、空间分布特征不同等问题，提出一种 DEFL 模型，该模型以并行的 EfficientNet-B0 网络和 DenseNet121 网络为特征提取网络，以提升模型特征提取能力，其次引入结合标签平滑策略的焦点损失函数以加强对识别困难样本的关注，模型的识别准确率高达 99.13%，参数量对比 ResNet 等主流模型大大减少。2024 年，于锦龙等人<sup>[10]</sup>针对现有卷积神经网络的小麦不完善颗粒识别模型复杂度高、难以部署等问题，提出一种基于 EfficientNet-B0 改进的轻量化小麦不完善颗粒识别 ML-EfficientNet 模型，识别准确率为 95.71%，参数量为 2.863M、浮点计算量为 0.376G。较改进前识别精度提升了 1.57 个百分点，参数量减少 60%。



近三年的国外研究中, 2022 年, Nawaz Marriam 等人<sup>[11]</sup>针对番茄叶片的健康部分与受影响部分之间在外观上存在巨大相似性的问题, 提出了一种基于 ResNet-34 的 Fester-RCNN, 该模型在公开数据库 PlantVillage 数据集上进行测试, 最终获得了 0.981 的平均精度值和 99.97% 的准确率, 以及 0.23s 的测试时间。2023 年, Bouni Mohamed 等人<sup>[12]</sup>采用卷积神经网络 CNN 并结合迁移学习来进行番茄叶片病害识别实验, 所用模型包含了 AlexNet、ResNet、VGG-16 和 DenseNet 等, 实验显示采用 RmsProp 优化方法的 DenseNet 模型取得了 99.9% 的最佳准确率。2023 年, Anjan Debnath 等人<sup>[13]</sup>使用 EfficientNetV2B2 和深度学习 DL 对植物病害进行检测, 结合迁移学习, 再基于 EfficientNetV2B2 预先的权重和 256 层密集层在番茄叶片病害数据集上训练, 后又通过 5 倍交叉验证方法取得了 99.02% 的平均加权训练准确率、99.22% 的平均加权验证准确率和 98.96% 的平均加权测试准确率。2024 年, Dennis Agyemanh Nana Gookyi 等人<sup>[14]</sup>针对传统番茄病害叶片诊断方法过于效率低下, 不适合实时应用的问题, 决定使用 TensorFlow 框架设计并优化高效卷积神经网络 CNN 架构, 包括 MobileNet、Inception、ShuffleNet、SqueezeNet、EfficientNet 和自定义深度神经网络 DNN, 在进行量化后, 最终 EfficientNet 以良好的 4.60MB 模型大小, 取得了 97.12% 的较高准确率, 证明了该模型在移动设备上部署的有效性。2024 年, Buchke Pratik<sup>[15]</sup>等人针对人眼难以辨别番茄病害叶片细微差异的问题, 采用深度学习中的高效网模型 EfficientNet 来准确识别了番茄病害叶片不同细微差异的病害, 研究发现当分别使用 3000、8000、10000 张图像来测试常见植物病害的检测效果时, 准确率分别为 97.3%、99.2% 和 99.5%。

综上所述, 在国内研究中, 尽管学者们通过改进网络结构、融合多网络特征等方法在作物病害识别上取得了较高的准确率, 但部分模型在参数量上仍有优化空间。模型虽然识别精度高, 但参数量较大, 这在一定程度上限制了其在资源受限场景下的应用, 难以通过普通手机或便携终端来实现实时病害识别。国外研究主要侧重于利用先进技术解决实际问题, 同样取得了较高准确率, 但模型在轻量化上的关注相对较少。部分模型在设计和训练过程中, 对硬件资源的要求较高, 难以在边缘设备上部署。

由此可见, 现有的研究在“轻量化架构 + 高精度识别”的平衡上存在一定的欠缺。因此, 本研究聚焦“资源受限场景下的番茄病害叶片高精度识别”问题, 借助高效卷积神经网络 EfficientNetB0 的轻量高效特性, 提出一种 DSC-EfficientNetB0 模型的番茄叶片病害识别研究。旨在通过结构轻量化和优化特征提取, 来突破现有研究在模型参数量和精度不平衡的局限, 最终实现无需依赖昂贵硬件即可在普通手机或便携终端上

快速且高精度地识别番茄叶片病害。

### 1.3 研究内容

结合现有深度学习方法技术在植物病害识别领域所面临的挑战来看。一方面，许多高精度模型在计算复杂度和参数量上过于庞大，难以满足在资源受限场景中实时部署的需求。另一方面，虽然一些轻量化模型在提升计算效率上有所突破，但其识别精度未能达到理想水平，尤其面对复杂且相似度高的病害图像时，往往出现漏诊和误诊现象。正因如此，本文的研究主要围绕“资源受限场景下的番茄叶片病害高精度识别”展开，重点解决“轻量架构 + 高精度识别”不平衡的问题。

由此，本研究提出了一种改进的 DSC-EfficientNetB0 模型，通过结合动态通道注意力（DCA）、可分离扩张卷积（SDC）和通道注意力（CAN），来实现“轻量架构 + 高精度识别”的平衡。通过创新模块的设计与结合，实现资源受限场景下的实时部署，并提供高精度番茄叶片病害识别。本研究将重点解决以下问题：

（1）模型轻量化：通过 DCA、SDC 和 CAN 模块的引入，减少模型的计算量和参数数量，使其适应手机或便携终端等低功耗设备。

（2）高精度识别：借助迁移学习，利用改进的 EfficientNetB0 作为主干网络，通过优化特征提取和注意力机制，提高模型在番茄叶片病害中的高精度识别。

### 1.4 技术路线

研究采用的技术路线如图 1-1 所示，整体路线按照数据集构建→模型构建→实验设计与分析，其主要研究过程如下：

（1）从 kaggle 平台的 PlantVillage 公共数据库收集原始番茄叶片病害图像数据。在筛选出 JPG 格式的图像后，对图像数据进行数据预处理。数据预处理操作经过了数据平衡、数据增强、数据划分、数据泄露检测以及数据归一化，最终得到了符合本研究的番茄叶片病害数据集。

（2）在本研究的番茄叶片病害识别 DSC-EfficientNetB0 模型的构建中，利用具有复合缩放策略，能够平衡网络深度、宽度和分辨率的 EfficientNetB0 模型作为主干，再集成动态通道注意力（DCA）、可分离扩张卷积（SDC）、通道注意力（CAN），进一步增强了 DSC-EfficientNetB0 的特征提取能力，并极大地减少了模型参数量。

（3）对比改进模型和五种主流深度学习模型，本文综合关键评估指标、准确率与损失曲线以及混淆矩阵等进行分析，展示了改进模型的轻量化与高精度优势。此外，通过消融实验，同样综合分析关键指标与混淆矩阵后，验证了态通道注意力（DCA）、可分离扩张卷积（SDC）、通道注意力（CAN）的集成优势。

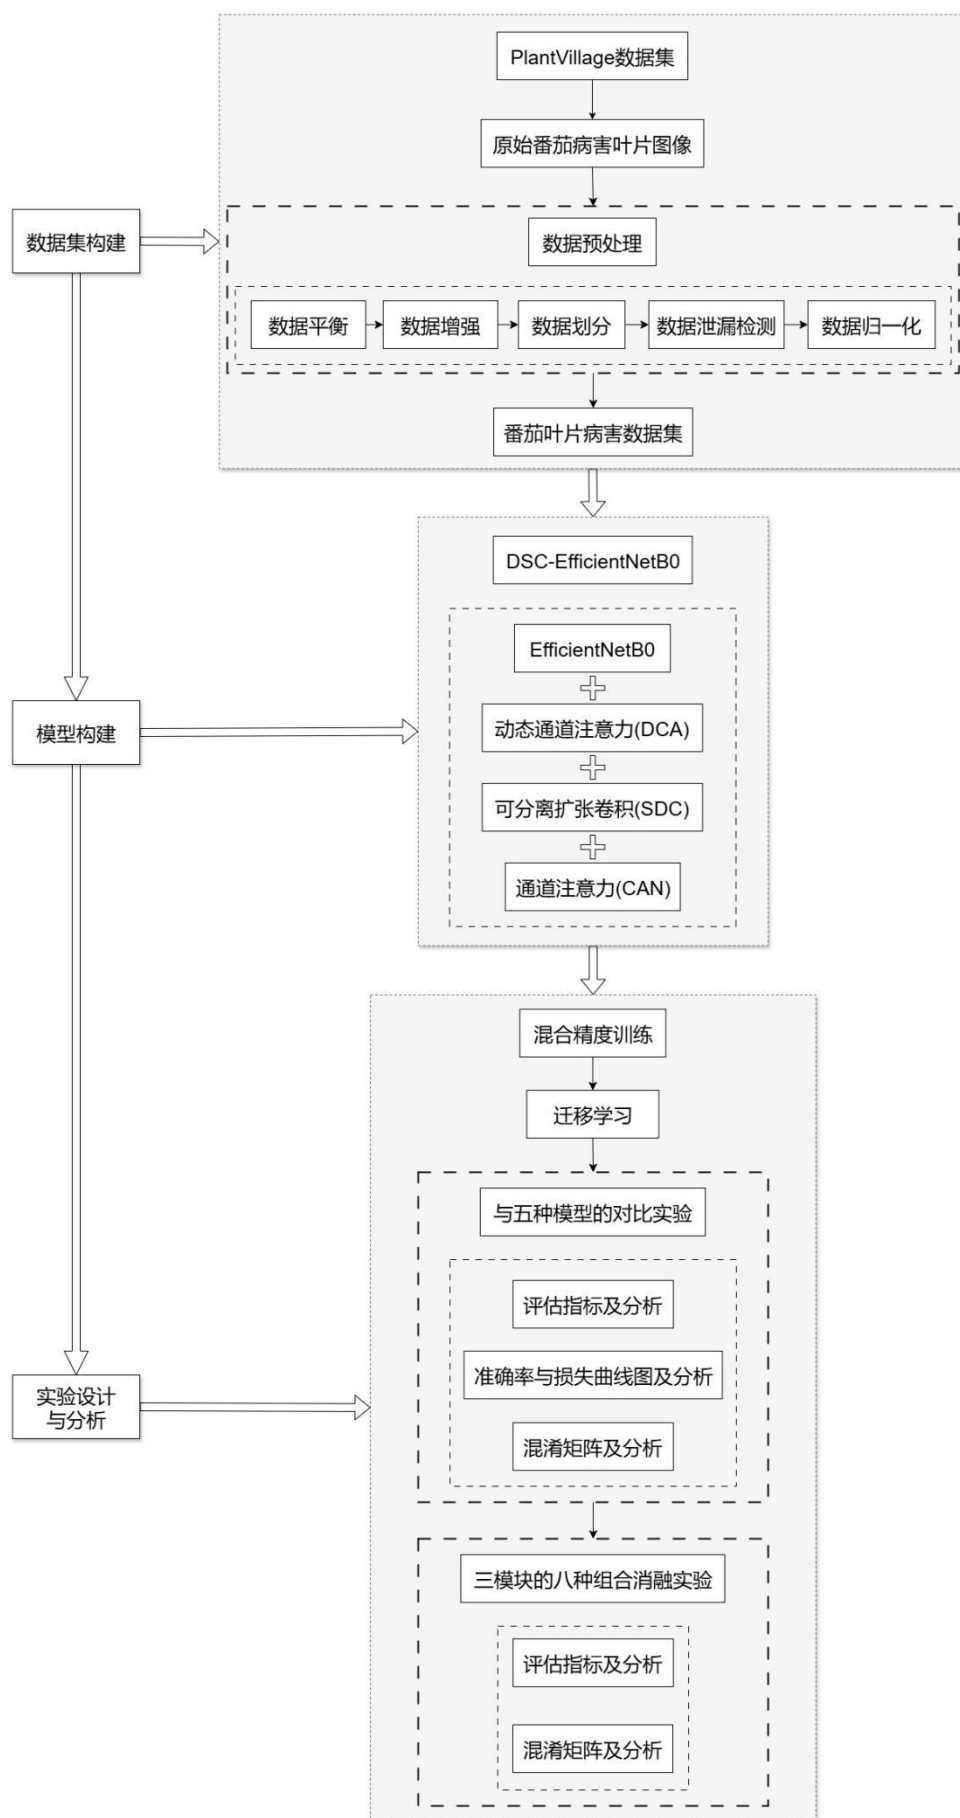


图 1-1 技术路线图

## 1.5 论文结构

本文的章节安排如下：

第一章绪论。首先，介绍研究背景与实际需求，其次，综述国内外在作物病害识别的研究现状，指出现有方法在精度与计算开销之间的矛盾，最后，明确本文的研究目标、研究内容及技术路线，并对各章节进行了简要概括。

第二章相关理论知识。根据本研究的关键技术，详细介绍研究所依赖的理论知识：卷积神经网络、EfficientNet 网络概述、混合精度训练、迁移学习、注意力机制。

第三章数据集与预处理。介绍了本研究所使用数据集的来源以及具体数据信息，并详细介绍数据预处理阶段的数据平衡与增强，以及数据的划分、泄露检测与归一化过程。

第四章基于 DSC-EfficientNetB0 的番茄叶片病害识别模型。详细介绍所提出 DSC-EfficientNetB0 的原理与网络结构等有关内容，以及动态通道注意力（DCA）、可分离扩张卷积（SDC）、通道注意力（CAN）三类模块的功能结构和相互作用。

第五章实验配置与结果分析。先介绍了本研究的实验环境和参数配置及模型评价指标等，其次展示与原版 EfficientNetB0、EfficientNetV2B0、MobileNetV3Small、ResNet50、DenseNet121 的对比实验数据三线表，以及验证集准确率和损失曲线、混淆矩阵热力图，然后通过三线表展示 DCA、SDC、CAN 三个模块的 8 种组合方式的消融实验结果及其对应的混淆矩阵热力图与分析，深入讨论模型在细粒度类别区分、收敛速度、泛化性和实地应用适配性方面的表现与原因。

第六章总结与展望。对全文工作进行总结，概括 DSC-EfficientNetB0 在识别精度、模型轻量化与实际部署潜力方面的主要贡献，同时基于本研究与当前学术的发展指出本研究的局限，提出后续优化研究方向。

## 2 相关理论知识

### 2.1 卷积神经网络

卷积神经网络（CNN）作为一种典型的深度神经网络，被广泛应用于计算机视觉和自然语言处理等领域。其核心思路是借助多层卷积核的滑动运算，自主学习数据特征，实现高效的分类或识别任务。目前卷积神经网络的架构主要包括输入层、卷积层、池化层、全连接层、输出层，可以分为两个阶段：特征提取（包括卷积层和池化层）和分类（包括全连接层和输出层）。特征提取阶段自主学习提取输入数据的有效特征，分类阶段则根据提取到的特征进行最终的判别。卷积神经网络的架构如图 2-1 所示。




图 2-1 卷积神经网络架构

输入层：用于接收输入图像数据。

卷积层：卷积层是 CNN 的核心部分，通过多个卷积核对输入图像进行局部感受野的滑动操作，提取出边缘、纹理等低级特征。每个卷积核能够学习到不同的特征表示，卷积操作后会生成多张特征图。

池化层：池化层通常跟随在卷积层之后，用于对特征图进行下采样，减少特征的空间尺寸，降低参数量和计算复杂度，同时增强特征的鲁棒性。常用的池化操作包括最大池化和平均池化。

全连接层：在经过多层卷积和池化操作后，得到的高维特征会被展平成一维向量，并输入到全连接层。类似于传统神经网络中的神经元结构，用于综合前面提取到的特征，实现更高层次的特征表达。

输出层：输出层通常用于分类任务，每个神经元对应一个类别，通过 Softmax 等激活函数输出各类别的概率分布，最终实现对输入图像的分类。

## 2.2 EfficientNet 网络概述

在深度学习领域的计算机视觉任务中，模型精度与效率（通常指计算量 FLOPs 和参数量）往往存在明显的权衡关系。传统卷积神经网络的设计模式，通过增加网络深度、宽度或输入图像分辨率来提升性能，但这会导致计算复杂度和参数量的急剧膨胀。虽然在一定程度上能够提升模型性能，但这种单一维度的扩展延伸往往效率低下，难以获得最佳精度与效率的平衡。

于是，为解决这一核心矛盾，谷歌研究团队于 2019 年提出了 EfficientNet 网络架构。其设计灵感来源于网络架构搜索，能够自动化搜索发现最优的网络结构。在传统的卷积神经网络中，深度、宽度和分辨率通常是独立调整的，而 EfficientNet 则基于这三者的联系提出了复合缩放的理念。EfficientNet 的复合缩放策略摒弃了单一维度扩展的思路，转而均衡地缩放网络深度（Depth）、宽度（Width）和输入分辨率（Resolution）这三个关键维度。其缩放原则基于一个观察：更大的输入图像需要更深、更宽的网络来捕捉更细粒度的特征，三者之间相互依赖。

### 2.6.1 复合缩放策略

复合缩放策略的核心优势在于：能够在有限的资源下，通过均衡三个维度，可以最大化模型的性能，获得远超单一维度扩展的收益。该策略通过一个统一的缩放系数  $\phi$  来同时控制三个维度的缩放比例：

- （1）深度： $d = \alpha^{\phi}$ ，代表网络层数的增加。
- （2）宽度： $w = \beta^{\phi}$ ，代表每层卷积核（通道）数量的增加。
- （3）分辨率： $r = \gamma^{\phi}$ ，代表输入图像尺寸的增加。

其中， $\alpha$ 、 $\beta$ 、 $\gamma$  是通过在基础小模型上进行网格搜索（通常在固定  $\phi=1$  的条件下）而确定的常数，代表了深度、宽度和分辨率的最优资源分配比例。满足约束条件  $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$ ，确保在  $\phi$  增加时，模型的总计算量（FLOPs）约增加  $2^{\phi}$  倍。 $\phi$  是由用户根据可用计算资源指定的缩放系数。 $\phi$  越大，模型越深、越宽、输入图像分辨率越高，模型精度通常更高，但计算量和参数量也显著增加。

### 2.6.2 基础架构：MBConv 模块与 SE 注意力

在确定了最优的复合缩放策略后，EfficientNet 需要一个高效的基础网络结构。于是，研究者决定采用基于反向残差线性瓶颈 MBConv（Mobile Inverted Bottleneck Conv）的结构来适配复合缩放理念，该模块最初在 MobileNetV2 中被证明是高效的。下面将详细介绍 MBConv 模块。

- （1）MBConv 模块

EfficientNetB0 的基本构建块是基于 MobileNetV2 提出的 MBConv 模块，也称为倒置残差结构，如图 2-2 MBConv 架构。




图 2-2 MBConv 架构

MBConv 架构主要包括：

- ①  $1 \times 1$  的普通卷积（升维作用，包含 BN 和 Swish 激活）
- ②  $k \times k$  的 Depthwise Conv 卷积（包含 BN 和 Swish 激活）， $k \times k$  有  $3 \times 3$  和  $5 \times 5$  两种情况
- ③ SE 模块
- ④  $1 \times 1$  的普通卷积（降维作用，包含 BN 和线性激活，线性激活  $y=x$ ）
- ⑤ Dropout 层

## （2）SE 模块（Squeeze-and-Excitation）

为了提高模型对重要通道特征的关注，在部分 MBConv 块（尤其是后面的层）中引入了 SE 注意力机制，SE 模块是一种经典的通道注意力机制，旨在提升卷积神经网络对特征通道间关系的建模能力。其核心思想是通过自适应地为每个通道分配权重，实现对重要特征的增强和对无关特征的抑制。SE 模块的架构如图 2-3 所示。它通过全局平均池化得到一个通道向量，然后通过两个全连接层，学习每个通道的权重（缩放因子），最后将权重与原特征图相乘（Scale），实现通道维度的自适应特征校准。

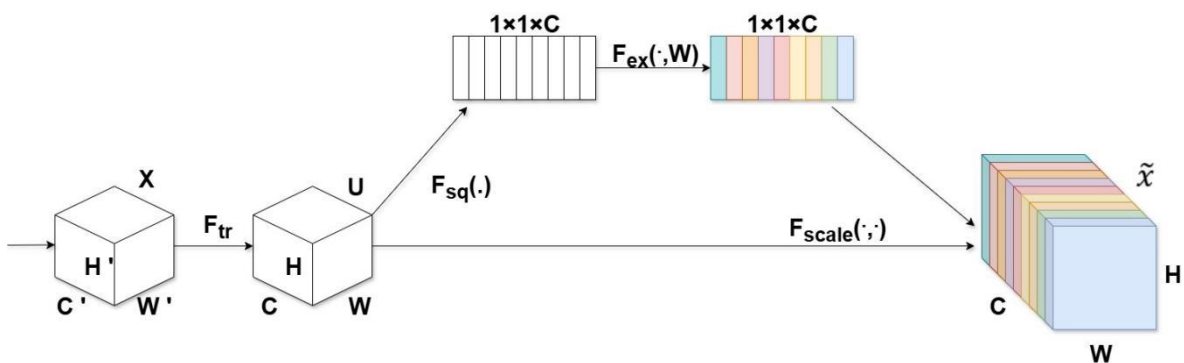


图 2-3 SE 架构

由图 2-3 可知，输入一个特征图  $X$ ，通过  $F_{tr}$  卷积计算得到  $C$  个大小为  $H \times W$  的特征图，共同组成一个新的特征图  $U$ ，再通过 SE 模块对该特征图进行加权调整。SE 模块的工作流程如下：

① 首先是压缩操作（Squeeze），采用全局平均池化方法，将各通道的空间特征聚合为单一数值，提取各通道的全局信息。

② 然后是激励操作（Excitation），该特征向量经全连接神经网络层构成的瓶颈结构进行非线性映射，通过建模通道间的非线性依赖关系，由激活函数导出各特征通道的显著性权重系数。

③ 最后是特征重标定（Scale），将该权重向量与输入特征图的每个通道逐元素相乘，实现对不同特征通道的自适应特征重标定，动态调整各通道的特征响应，提高模型提取特征的能力。

### 2.6.3 EfficientNetB0 概述

EfficientNet 系列包含从 B0 到 B7 等多个版本，其改进策略是先设计一个性能良好的基础网络 EfficientNetB0，然后通过复合缩放策略（逐步增大 $\phi$ ）来生成更大的模型 B1 到 B7 系列等。其中，EfficientNetB0 是整个系列的起点和基础模型，也是该系列中最为轻量化的基础模型，其核心优势是即使在计算资源和参数量有限的状态下，也能提供强大的特征提取能力和较高的识别精度。与本研究“资源受限场景下的番茄叶片病害高精度识别”的核心目标高度契合，是本研究进行改进优化的核心基础。它的模型结构如图 2-4 所示。

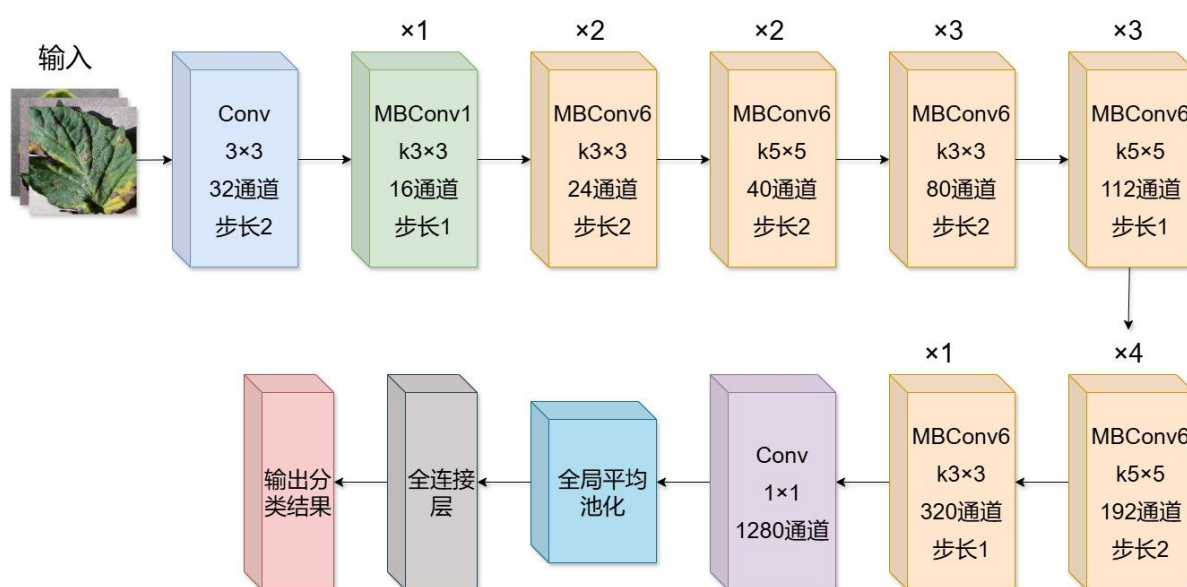


图 2-4 EfficientNetB0 架构

其中，EfficientNetB0 以 3×3 卷积层作为起始特征提取模块，随后通过 16 组高效的 MBConv 模块（包含 SE 注意力机制）对特征进行逐步的提取和增强。在网络结构图中可以看到，它合理穿插了不同卷积核大小、通道数和步长设置，并在后端通过 1×1 卷积、全局平均池化和全连接层实现高效的特征整合与分类输出。通过各模块的



高效协作，使得 EfficientNetB0 在保证高精度的同时，极大地降低了模型的计算开销和存储需求。

### 2.3 混合精度训练

混合精度训练（Mixed Precision Training）是一种通过使用不同精度的数据类型来加速深度学习模型训练的技术。其核心思想是让计算中的某些操作使用较低的数值精度（如 16 位浮点数，FP16），而其他操作则使用较高精度（如 32 位浮点数，FP32）。FP32 精度通常用于模型的权重和梯度表示，而 FP16 精度则可以用来存储中间计算结果。这种技术通过灵活选择数值精度，来实现更高效的计算，可以在确保模型精度不受影响的前提下，进一步减少计算资源的消耗，提高训练效率。

### 2.4 迁移学习

迁移学习（Transfer Learning）是指利用在某一任务上获得的知识，来加速或提高另一个任务的学习效果。与传统机器学习方法不同，迁移学习关注如何有效地将已经学到的知识从一个领域转移到另一个领域。其基本思想来源于人类认知过程，即我们可以将从一个任务中学到的经验，应用于处理新的相关任务。迁移学习在深度学习领域中的应用越来越广泛，特别是在图像识别、语音处理和自然语言处理等任务中。迁移学习的核心目标是通过在源任务上训练模型并获取知识，来减少目标任务中的训练时间并提高模型性能，尤其是在目标任务数据有限的情况下。

### 2.5 注意力机制

在深度学习中，注意力机制（Attention Mechanism）的核心作用在于对输入数据中不同局部特征的重要程度进行动态评估与加权分配，通过这种有侧重点的信息处理，能够增强模型对关键特征的捕捉能力，进而提升整体性能表现。注意力机制的设计灵感源自于人类在处理信息时常常有意识地将精力集中于某些部分，而忽略其他部分。神经网络中的注意力机制通过学习输入特征中每个部分的重要性来对不同的输入部分进行加权，从而帮助模型更好地理解 and 处理信息。

### 3 数据集与预处理

#### 3.1 数据集

本研究使用的番茄病害叶片图像数据集源自全球农业计算机视觉领域广泛采用的权威数据集——PlantVillage 数据库。该数据集由 Abdallah Ali 等研究者于 2019 年通过 Kaggle 平台公开发布，旨在通过人工智能技术解决因植物病而引发的全球粮食安全问题。PlantVillage 是当前植物病害识别研究中规模最大标注最完善的公共数据集之一，其原始版本包含 54,306 张高质量叶片图像，它包含苹果、蓝莓、樱桃、玉米、葡萄、橙子、桃子、胡椒、土豆、树莓、大豆、南瓜、草莓、番茄等 14 类作物样本的病害及健康状态类别图片。其中，番茄病害叶片被分为 10 类分别是：Bacterial spot（细菌性斑点病）、Early blight（早疫病）、Healthy（健康）、Late blight（晚疫病）、Leaf mold（叶霉病）、Septoria leaf spot（斑点叶斑病）、Two spotted spider mite（双斑蜘蛛螨）、Target spot（靶斑病）、Mosaic virus（花叶病）、Yellow leaf curl virus（黄叶卷曲病）。

本研究从全部番茄病害叶片类别中总共选取 18159 张 JPG 格式的图像用于实验，每张图像分辨率都是 256×256 像素。图像在受控条件下拍摄，叶片放置于纯色背景中（多为灰色），确保病害区域清晰可辨，减少环境干扰。番茄病害叶片如图 3-1 所示。

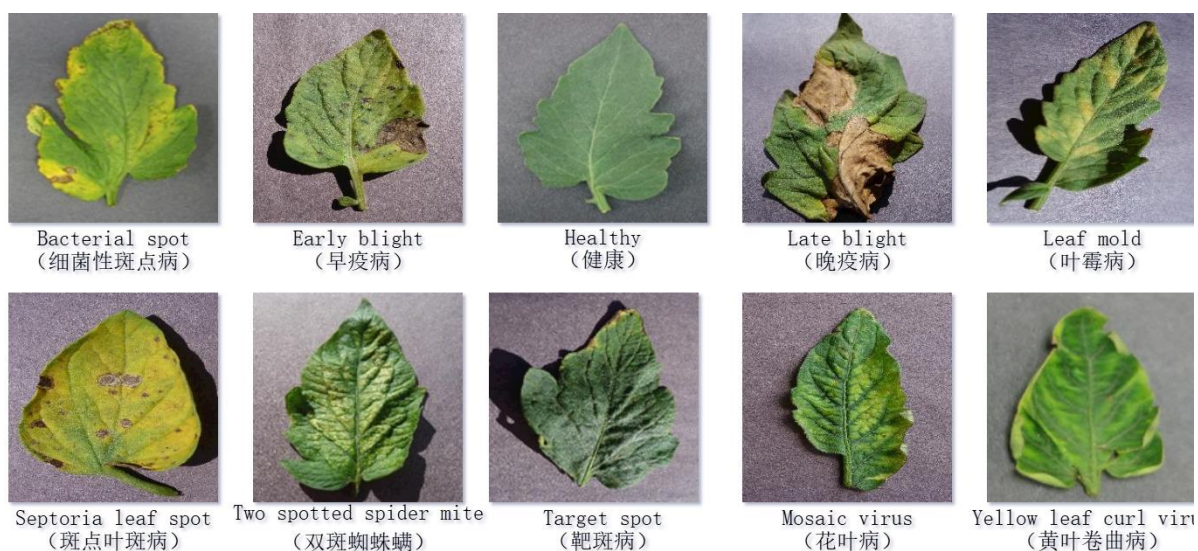


图 3-1 番茄病害叶片图像

#### 3.2 数据预处理

##### 3.2.1 数据平衡与增强

结合原始番茄叶片病害类别柱状图来看，如图 3-2 所示，10 个类别的样本数各不

相同，差异极大严重不平衡，其中 Yellow leaf curl virus（黄叶卷曲病）数量最多为 5357 张，Mosaic virus（花叶病）数量最少只有 373 张，这会导致模型训练时自然倾向于样本量大的类别（如 5357 张的类别），导致对小样本类别（如 373 张）的识别能力极差。



图 3-2 原始番茄叶片病害种类柱状图

因此为了减少极端值的影响，并兼顾其他类别的样本量，本研究结合 10 个类别样本数的中位数 1633.5，平衡每个类别样本数都为 1500 张，由此，大于 1500 的有 6 个类别，小于 1500 的只有 4 个类别，这样就适合只对 4 个样本类别进行过采样，其余进行欠采样，大大减少工作量。对于过采样，本研究使用数据增强技术中的水平翻转、上下翻转、90 度旋转、180 度旋转的四种图像几何变换技术，欠采样则是随机选取 1500 张即可。最终的数据总量为 15000 张图像，平衡后的数据如图 3-3 所示

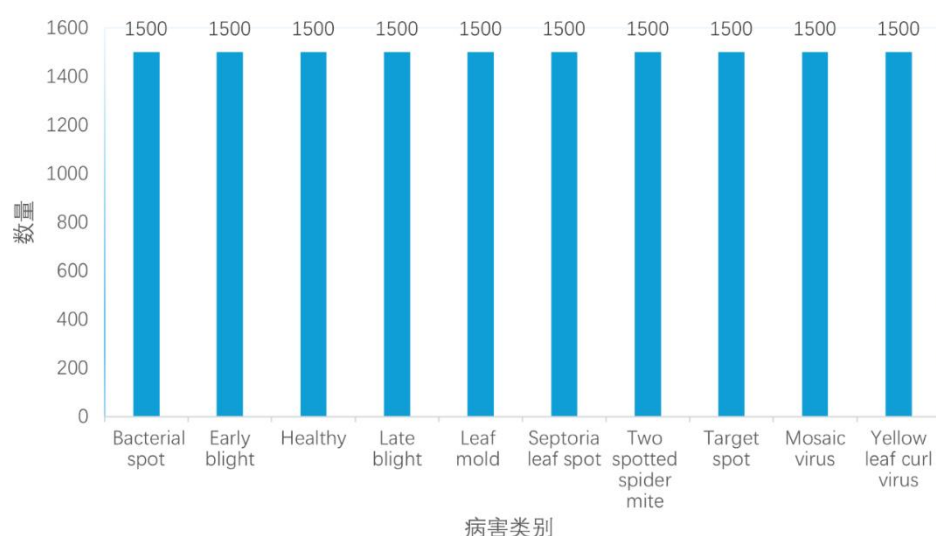


图 3-3 平衡后的数据柱状图

其次，因为 10 个类别原始图像分辨率都是 256×256，为了减少无关背景对模型

特征提取的干扰，适配预训练模型，充分发挥模型主流输入尺寸 224×224 分辨率的预训练优势，以及降低计算量和显存占用，提高推理和训练速度，满足大规模实验等，在数据增强阶段采用中心裁剪方法将分辨率 256×256 像素的图像全部裁剪为分辨率 224×224 像素。

3.2.2 数据划分、泄露检测与归一化

在完成数据平衡与增强后，本研究共获得 15000 张分辨率为 224×224 的番茄叶片图像。为确保模型训练的科学性和评估的客观性，研究采用分层随机划分的方式，将数据集按照 7:1.5:1.5 的比例划分为训练集、验证集和测试集。具体划分如下：

训练集（train）：占总数据量的 70%，共 10500 张图像，用于模型的训练学习和特征提取。验证集（val）：占总数据量的 15%，共 2250 张图像，用于模型训练过程中的超参数调整和早停策略优化，以预防模型过拟合。测试集（test）：占总数据量的 15%，共 2250 张图像，用于最终模型性能的独立评估。

在数据集划分完成后，为进一步确保训练集、验证集和测试集之间没有重复数据，本研究采用哈希值比对技术对划分后的数据集进行了数据泄露检测。具体方法为：对每一张图像文件计算其内容的 MD5 哈希值，并在不同数据子集之间进行哈希值比对，判断是否存在重复图像。如表 3-1 所示，通过对训练集、验证集和测试集两两之间的哈希值进行比对，最终检测结果显示三者之间不存在任何重复图像，数据集划分完全独立，未发生数据泄露。这为后续模型训练和评估的科学性与可靠性提供了有力保障。

表 3-1 数据泄露检测

训练集	验证集	测试集	数据是否泄露
√		√	否
√	√		否
	√	√	否

完成数据泄露检测后，为进一步加速模型训练进程，提高训练时的稳定性，接下来需要对已经划分好的训练集、验证集和测试集图像数据执行归一化操作，具体做法是将每个像素的 RGB 值均除以 255，使所有像素值都被压缩到[0, 1]区间内。这一处理能够有效避免训练过程中因数值规模过大引发的梯度异常问题，对增强模型训练的稳定性起到显著作用。

## 4 基于 DSC-EfficientNetB0 的番茄叶片病害识别模型

面对传统高精度模型因计算复杂度居高不下，以及轻量化模型普遍在训练不稳定和识别精度不足的问题，本文在前期相关研究的基础上，提出了一种融合动态通道注意力（DCA）、可分离扩张卷积（SDC）和通道注意力（CAN）模块的改进型 DSC-EfficientNetB0 模型。该模型兼顾了网络结构的轻量化设计和计算高效性，显著提高对番茄叶片复杂病害特征的提取与识别能力。本章将具体阐述 DSC-EfficientNetB0 模型的整体架构设计和关键模块的运行原理，及其在番茄叶片病害识别任务中的实际应用效果。

### 4.1 DSC-EfficientNetB0 模型设计思路

#### 4.1.1 EfficientNetB0 作为主干网络的选择

本研究所提出的 DSC-EfficientNetB0 模型之所以选取 EfficientNetB0 作为主干网络，是因为 EfficientNet 系列的核心在于采用复合缩放策略。通过同步优化网络深度、通道宽度和图像分辨率，在参数量规模和实际计算量之间达成了更精细的平衡。对比传统卷积神经网络，EfficientNet 借助复合缩放机制，能在显著降低计算成本的前提下，高效完成高质量的特征学习任务。

其中，在同 EfficientNet 系列中，EfficientNetB0 属于参数量少、计算复杂度最低的轻量级版本，且依旧在图像识别等任务中保持优异的识别精度。正因如此，在边缘设备这类资源受限的实际环境中，EfficientNetB0 的优势尤为突出，能对于番茄叶片病害识别任务做到精准契合。

#### 4.1.2 结构改进的必要性

虽然 EfficientNetB0 已经展现出了足够的优势，但在番茄叶片病害识别任务中，由于番茄叶片病害具有相似性和复杂性，尤其是在细粒度特征的提取上，如果能够继续改进优化 EfficientNetB0，增强其特征提取能力，或继续降低模型参数量，减少资源消耗，那么它将更好的适配低边缘设备。

为此，本研究具体的改进方向为：

- （1）增强模型对局部细节特征的提取能力，提升对不同病害的识别表现。
- （2）模型以更低的参数量与计算复杂度在低资源环境下实现高精度识别。

#### 4.1.3 引入新模块

由本文的第二章介绍可知迁移学习在深度学习领域中发挥着重要作用，因此在迁移学习的运用下，EfficientNetB0 在番茄叶片病害识别上拥有非常高的识别精度，由

此本研究在确保 DSC-EfficientNetB0 模型与 EfficientNetB0 在识别精度与计算复杂度持平的性能下，引入三个创新模块：动态通道注意力（DCA）、可分离扩张卷积（SDC）和通道注意力（CAN）。

#### （1）动态通道注意力（DCA）

动态通道注意力通过自适应地调整每个通道的权重，从而使得网络能够根据输入图像的不同特征，动态地关注最重要的通道信息。对于番茄叶片病害识别而言，DCA 能够有效提高网络对病害区域特征的敏感度，特别是在复杂病害类型的识别中，动态调整权重，显著提高识别精度。

#### （2）可分离扩张卷积（SDC）

扩张卷积通过增加感受野，能够捕捉更大范围的上下文信息。然而传统扩张卷积容易引发“空洞”效应，影响特征图的质量，而可分离扩张卷积通过将卷积操作分解为深度卷积和逐点卷积，既能扩大感受野，又能大幅降低参数量和计算复杂度。这使得整个模型在提取更丰富的全局特征时，不会增加计算负担，反而能够有效减少模型参数量与计算复杂度。

#### （3）通道注意力（CAN）

通道注意力模块进一步优化了特征图中的通道权重，使得模型能够更专注于重要的通道，并抑制不相关的特征，能够辅助模型更好地区分不同病害区域，提升多类别识别的准确性。

### 4.2 DSC-EfficientNetB0 模型

如图 4-1 所示，本研究提出一种基于改进 EfficientNet 的番茄叶片病害识别 DSC-EfficientNetB0 模型，其中该模型的主干网络 EfficientNetB0 在本文第二章已经详细介绍，它是由一系列卷积层和多个 MBConv 模块组成。输入为  $224 \times 224 \times 3$  的图像，首先经过一个  $3 \times 3$  卷积核、输出通道 32、步长为 2 的卷积层，随后是多个 MBConv 模块。MBConv 模块是 EfficientNet 的核心组件，其包含不同数量的通道和步长，如 MBConv1 有 16 通道、步长为 1，MBConv6 有 24 通道、步长为 2 等。这些模块逐步对特征进行提取，最后经过一个  $1 \times 1$  卷积核、输出通道 1280 的卷积层输出  $7 \times 7 \times 1280$  的特征图。

后续将前一个模块的输出作为后一个模块的输入，EfficientNetB0 的输出  $7 \times 7 \times 1280$  特征图经过动态通道注意力（DCA）操作，得到相同的  $7 \times 7 \times 1280$  特征图输出，该模块通过动态调整通道权重来突出重要的特征通道，抑制不重要的通道，从而提升模型对关键特征的关注度；又经过可分离扩张卷积（SDC）得到一个  $7 \times 7 \times 64$  特



征图的输出，这个模块结合了可分离扩张卷积的优势，能够在扩大感受野，捕捉更多尺度特征的情况下，进一步降低参数量与计算复杂度，它将输入的特征图进行处理，输出具有不同通道数和空间维度的特征图；又经过通道注意力（CAN）得到相同的  $7 \times 7 \times 64$  特征图输出，该模块进一步对特征通道进行加权，强化重要的特征通道，抑制不重要的通道，提升模型的特征表达能力和对相似特征的区分能力。

后又经过全局平均池化（GAP）操作将  $7 \times 7 \times 64$  的特征图转换为长度为 64 的特征向量，通过对每个通道的特征进行平均，减少特征图的空间维度，同时保留重要的特征信息；后将经过池化后的特征向量进行全连接操作，扩展特征维度，将 64 维的特征向量转换为 1024 维的特征向量，用于后续的分类操作；又经过批归一化（BN）对全连接层输出的特征进行批归一化处理，加速模型训练过程，提高模型的收敛速度和稳定性，通过对每一批数据的特征进行归一化，使得特征分布更加稳定；又经过 Dropout 操作，随机地丢弃一半神经元，以防止过拟合，增强模型的泛化能力；最后将经过 Dropout 层处理后的特征向量进行全连接操作，输出长度为 10 的向量，用于对输入图像进行 10 分类。

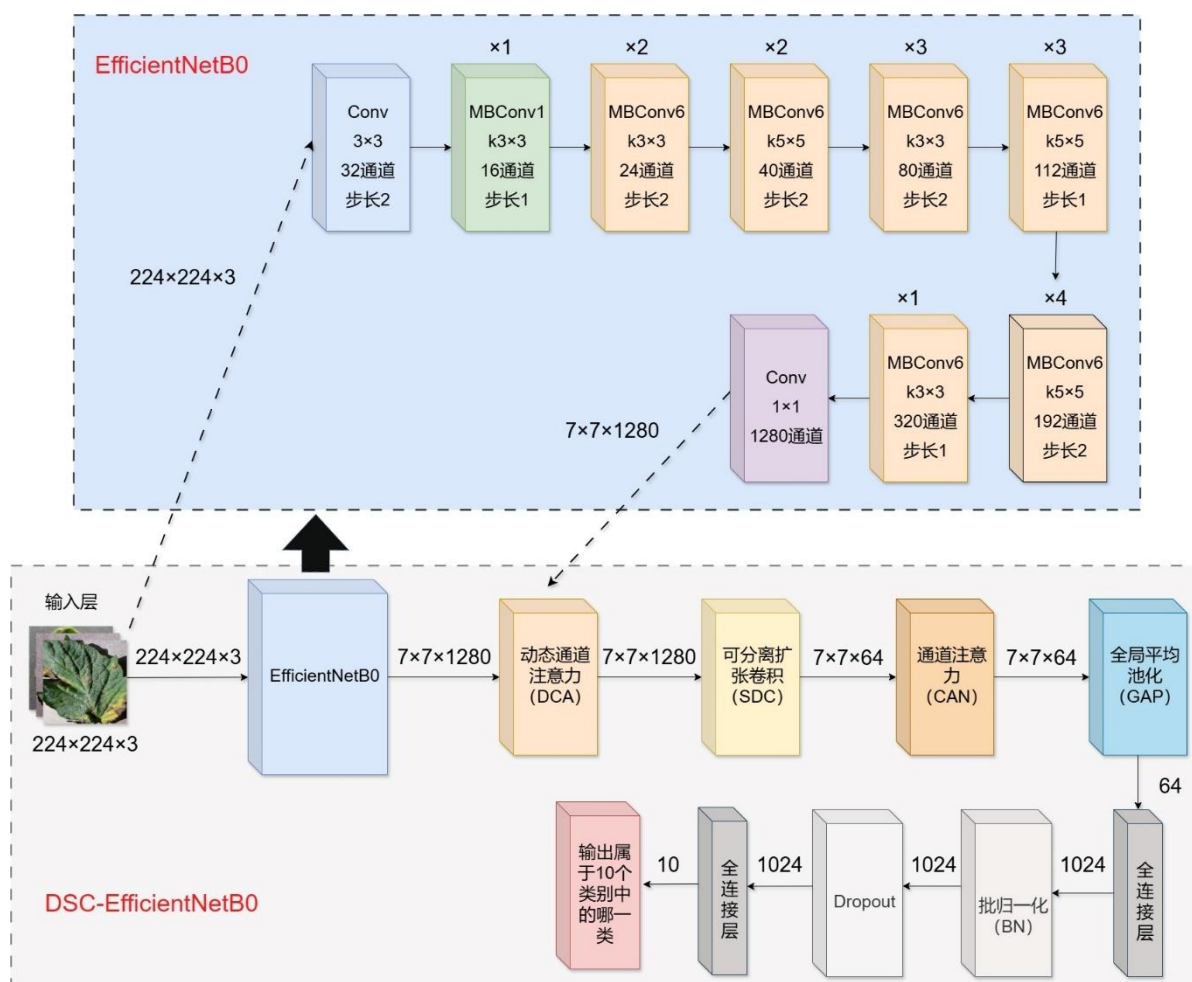


图 4-1 DSC-EfficientNetB0 模型架构

### 4.3 动态通道注意力 (DCA)

动态通道注意力 (Dynamic Channel Attention, DCA) 是深度学习中的一种自适应机制, 通过实时调整网络中各特征通道的权重占比, 提取输入特征图的高权重特征, 来提高模型的识别能力, 有效解决特征不均衡与背景干扰问题。

#### 4.3.1 动态通道注意力的原理及架构

本研究中, DCA 根据输入特征图动态地调整每个通道的权重, 灵活地提取出数据中最相关的特征信息, 大大提高了模型对多变数据特征的适应能力。如图 4-2 所示, 动态通道注意力的架构。

##### (1) 输入特征图

输入特征图是网络的原始输出或卷积层的输出, 通常表示为三维张量:  $H \times W \times C$  即特征图的高度、宽度以及通道数也就是  $7 \times 7 \times 1280$ 。输入特征图包含了图像中的全部信息, 每个通道空间上都有对应的特征。

##### (2) 全局平均池化(GAP)

全局平均池化 (Global Average Pooling, GAP) 通过对特征图的空间维度位置逐个计算平均值, 把原本分布在空间上的特征信息压缩成每个通道对应的单一统计量。在 DCA 中, 进行全局平均池化能够把每个特征通道里所有的特征值做平均处理, 将其压缩成一个代表该通道在整个特征图上的全局特征情况的标量。见公式 (4-1), 对于每个通道  $C$  的输入特征图  $X_c$  (大小为  $H \times W$ ), GAP 输出一个通道的全局平均值:

$$Z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X_c(i, j) \quad (4-1)$$

这样, GAP 的输出是一个大小为  $1 \times C$  的向量, 表示每个通道的全局信息。其中,  $Z_c$  是第  $C$  个通道的全局特征。

##### (3) 全连接层 (FC) 与 Swish 激活函数

接下来, GAP 的输出  $Z$  会被传入一个全连接层 (FC), 此时通过这个全连接层来学习通道之间的关系。该全连接层的输出经过 Swish 激活函数, Swish 是一个平滑的非线性激活函数, 具有较好的梯度流动性能。全连接层的作用是通过对于  $Z$  进行线性变换来生成一个新的向量  $h$ , 该向量用于描述每个通道的重要性。公式 (4-2) 如下:

$$h = W_1 Z + b_1 \quad (4-2)$$

其中,  $W_1$  是全连接层的权重,  $b_1$  是偏置项。

随后, Swish 激活函数会作用于全连接层的输出:



$$Swish(x) = x \cdot \sigma(x) \quad (4-3)$$

其中， $\sigma(x)$  是 Sigmoid 激活函数：

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (4-4)$$

Swish 激活函数可以增强信息的流动，具有平滑的非线性特性。

#### (4) 全连接层 (FC) 与 Sigmoid 激活函数

在经过 Swish 激活后，得到的向量  $h$  会传递给第二个全连接层，并通过 Sigmoid 激活函数对每个通道的权重进行压缩。Sigmoid 函数将每个通道的权重压缩到 (0,1) 范围内，使得每个通道的重要性变得可调节。全连接层输出的向量通过 Sigmoid 激活函数计算通道权重：

$$W = \sigma(W_2 h + b_2) \quad (4-5)$$

其中， $W_2$  是第二个全连接层的权重， $b_2$  是偏置项， $W$  表示每个通道的权重向量。

#### (5) 重塑层

在经过 Sigmoid 激活后的输出  $W$  是一个大小为  $1 \times C$  的向量，它表示每个通道的动态权重。为了将这个权重应用到输入特征图中，需要对其进行重塑，使其能够与输入特征图的形状匹配。通常，重塑操作将权重向量  $W$  转换为大小为  $1 \times 1 \times C$  的张量，便于与输入特征图进行逐通道的加权。重塑操作见公式 (4-6)：

$$W_{reshape} = Reshape(W) \in R^{1 \times 1 \times C} \quad (4-6)$$

这样，重塑后的权重  $W_{reshape}$  可以与输入特征图  $X$  进行逐通道的加权。

#### (6) 元素级乘法

在重塑后的权重  $W_{reshape}$  和输入特征图  $X$  具有相同的通道数  $C$  后，我们可以进行元素级的乘法操作。元素级乘法的目的是根据计算得到的通道权重来调整输入特征图中的每个通道的重要性。见公式 (4-7)：

$$X_{out}(h, w, c) = X(h, w, c) \cdot W_{reshape}(c) \quad (4-7)$$

其中， $c$  表示通道索引， $h$  和  $w$  分别表示空间维度。通过这个元素级乘法，输入特征图的每个通道都会根据其对应的动态权重进行调整，从而得到加权后的特征图。

#### (7) 输出特征图

经过上述操作后，得到的输出特征图  $X_{out}$ ，此时，各个通道的权重已经根据输入特征图的内容和动态调整策略进行了优化，能够更好地表示重要特征。输出特征图的大小与输入特征图相同，形状为  $7 \times 7 \times 1280$ ，表示通道数与空间维度未发生变化，但每个通道的特征内容已经被注意力机制加权。




图 4-2 动态注意力（DCA）架构

## 4.4 可分离扩张卷积（SDC）

在深度学习的计算机视觉领域中，由于传统的卷积操作在处理图像中的长距离依赖和多尺度信息时往往难以同时捕捉到这些关键特征。为解决该问题，研究人员提出了可分离卷积（Separable Convolution）和扩张卷积（Dilated Convolution）等技术。在这两种技术的基础上，进一步将二者融合，得到了可分离扩张卷积（Separable Dilated Convolution, SDC），这一融合技术很快成为新的研究热点，并在图像处理等多个任务中取得了显著的成果。

### 4.4.1 可分离扩张卷积的原理及架构

本文的可分离扩张卷积就是将扩张卷积的“增大感受野”的特性，嵌入到可分离卷积中，具体是在可分离卷积的深度卷积阶段融入扩张卷积操作，以此在提升卷积神经网络感受野的同时，大幅减少模型的计算复杂度和参数量。本研究先通过带扩张属性的可分离卷积（在深度卷积环节借助扩张率扩大特征捕捉范围）处理输入，再通过 $1\times 1$ 卷积进一步融合特征。这样一来，模型既能有效捕捉番茄叶片病斑大小不一样的特征，又能依托可分离卷积的拆分运算降低计算量，避免资源浪费。下面我将结合图 4-3 可分离扩张卷积架构，逐一解释每一层的作用及其数学公式。

#### （1）输入特征图

表示为三维张量： $H\times W\times C$  即特征图的高度、宽度以及通道数  $7\times 7\times 1280$ 。这一层是前一层动态通道注意力的输出，输入特征图中的每个像素值表示某个特征的强度，而各个通道代表不同的特征。

#### （2）可分离扩张卷积

该部分结合了可分离卷积和扩张卷积，其中扩张卷积是作为可分离卷积的一部分存在，并不是单独的一层，只在可分离卷积的内部进行。

可分离卷积的核心作用是在保证模型性能基本不变的前提下，大幅减少计算量和参数量，从而让模型更轻量化、运行更快。可分离卷积又分为深度卷积与逐点卷积，其中深度卷积通过单独对每个通道做卷积，只提取通道内的空间特征，不跨通道计算，

这一步能大幅减少计算量。

扩张卷积在卷积核中引入空洞来扩大感受野，不增加卷积核大小就能捕捉更广泛的上下文信息，特别适用于需要全局感知的任务（如图像分割、目标检测等）。设输入  $X \in R^{H \times W \times C}$ ，扩张卷积核  $W_{dilated} \in R^{k \times k}$ ，扩张率为  $d$ ，公式见（4-8）：

$$Y_{conv1}[i, j, c] = \sum_{m=-\frac{k}{2}}^{\frac{k}{2}} \sum_{n=-\frac{k}{2}}^{\frac{k}{2}} X[i + d \cdot m, j + d \cdot n, c] \cdot W_{dilated} \left[ m + \frac{k}{2}, n + \frac{k}{2} \right] \quad (4-8)$$

其中， $X[i, j, c]$  是输入特征图  $X$  在位置  $i, j$  和通道  $c$  的值。 $W_{dilated}$  是卷积核的权重， $d$  是扩张率。

### （3）逐点卷积（Conv2D）

逐点卷积是一个  $1 \times 1$  卷积，属于可分离卷积的一部分。它的作用是对深度卷积输出的每个通道进行线性组合，从而整合信息，完成通道之间的信息融合。在上一个卷积（深度卷积）后，逐点卷积通过  $1 \times 1$  卷积对每个位置的所有通道进行加权求和，从而产生新的特征图。逐点卷积相当于对不同通道的信息进行加权组合。见公式（4-9）：

$$Y_{conv2}[i, j] = \sum_{c=1}^C X_{depthwise}[i, j, c] \cdot W_{pointwise}[c] \quad (4-9)$$

其中， $X_{depthwise}[i, j, c]$  是深度卷积输出的第  $i, j$  位置和通道数  $C$  的值。 $W_{pointwise}[c]$  是逐点卷积核的权重， $C$  是输入通道数。

### （4）输出特征图

经过可分离扩张卷积操作后，得到的输出特征图为  $7 \times 7 \times 64$ ，输出特征图通道数由 1280 减少到 64。在不需要增加额外的参数量和计算量的同时，能显著扩展感受野，提高模型对大尺度信息的感知能力。

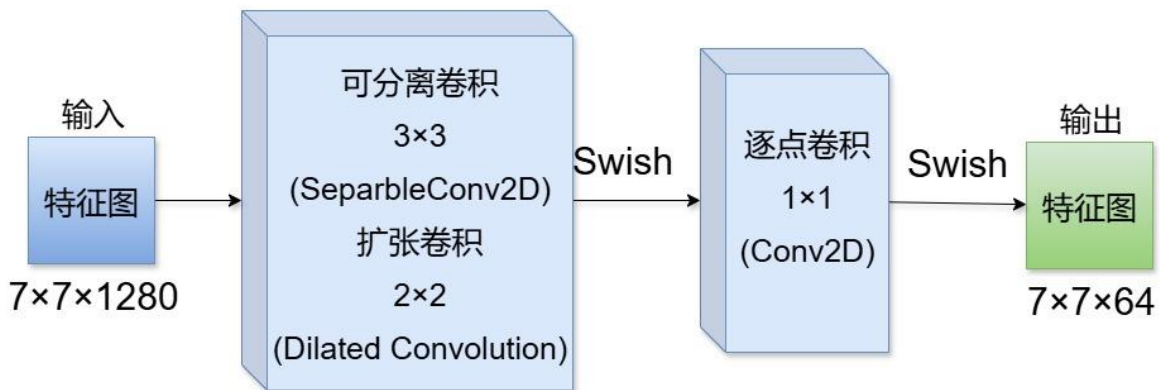


图 4-3 可分离扩张卷积（SDC）架构

## 4.5 通道注意力（CAN）

通道注意力（Channel Attention Network, CAN）的核心操作是对输入特征图的各个通道分别计算并赋予不同的权重值，从而使模型在学习的过程中自动去关注那些携带关键信息的通道。其主要目标是通过差异化权重分配，来增强有效特征。

### 4.5.1 通道注意力的原理及架构

在卷积神经网络中，特征图是通过多层卷积操作提取的，其中每一层的输出包含了输入图像不同维度的特征信息。需要注意的是，由于不同通道对最终任务的贡献差异很大，有的通道能清晰呈现病斑特征，有的通道却只包含背景噪声，所以在每一层对通道做加权调整就显得特别关键。而通道注意力机制（CAN）正是为解决问题而专门设计的，它通过自动学习每个通道的重要程度，来增强网络的表达能力。接下来我将结合图 4-4 的通道注意力架构图来详细解析各个模块及其作用。

#### （1）输入特征图

输入特征图是来自上一个可分离扩张卷积的输出，形状同样为  $H \times W \times C_{int}$ ，其中， $C_{int}$  是输入通道数。输入特征图包含了来自不同卷积核所提取的特征信息。通过通道注意力机制，我们通过对这些通道进行加权，强化有意义的特征，抑制无用的特征。

#### （2）卷积层 1

卷积层 1 的作用是通过  $3 \times 3$  的卷积核对输入特征图进行局部特征提取。通过该卷积操作，模型不仅能够学习到输入特征图的空间分布结构，还能通过减少输出通道数来降低计算复杂度。该卷积的输出形状为  $H \times W \times C_{out}$ ，其中  $C_{out} = C_{int} \div reduction\_ratio$ 。它的作用是将输入特征图的信息压缩为更小的维度，有效减少模型整体计算量，最大限度保留输入信息的关键部分。卷积操作对输入特征图  $X$  和卷积核  $W_1$  进行卷积运算，随后应用 Swish 激活函数。见公式（4-10）：

$$X_1 = Swish\left(Conv2D(X, W_1)\right) \quad (4-10)$$

其中， $X$  为输入特征图， $W_1$  为卷积核， $X_1$  为卷积层 1 的输出。

#### （3）卷积层 2

卷积层 2 是一个  $1 \times 1$  的卷积操作，专门用来生成通道注意力图。因为  $1 \times 1$  卷积只在通道这个维度上做运算，没有涉及空间上的邻域信息，所以计算量明显更小。它的主要作用是恢复原始通道数并为每个通道分配一个注意力权重。该层输出的通道数与输入特征图的通道数完全一致，而且会使用 Sigmoid 激活函数将权重值牢牢限制在  $[0,1]$  区间内。通过这种方式，模型能够根据任务需求灵活调整每个通道的贡献大小，

见公式（4-11）：

$$A = \text{Sigmoid}\left(\text{Conv2D}(X_1, W_2)\right) \quad (4-11)$$

其中， $A$  为注意力图， $W_2$  为卷积核， $X_1$  为卷积层 1 的输出。

#### （4）注意力图

注意力图  $A$  是一个形状为  $H \times W \times C_{\text{int}}$  的张量，表示每个通道的注意力权重。通过通道注意力机制，模型为每个通道分配了一个权重值，该权重值表示该通道在当前任务中的重要性。注意力图的作用是动态调整每个通道的贡献，使得网络能够关注到更重要的通道。

#### （5）加权输出特征图

加权输出特征图是通过将注意力图  $A$  与输入特征图  $X$  逐元素相乘得到的。每个通道的权重会影响其在输出中的贡献，强化了重要通道的特征，抑制了不重要的通道。这一过程确保了网络能够根据任务要求自适应地调整通道的重要性，从而提升模型的性能。见公式（4-12）：

$$Y = X \times A \quad (4-12)$$

其中， $Y$  为加权后的输出特征图。

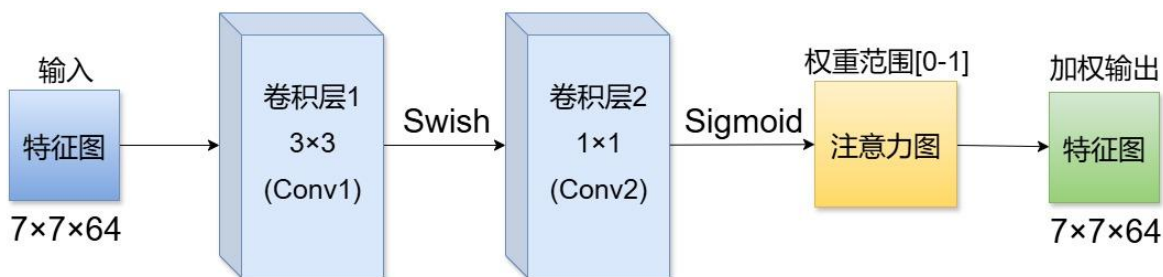


图 4-4 通道注意力（CAN）架构

## 5 实验配置与结果分析

### 5.1 实验设置及评价指标

#### 5.1.1 实验设置

本研究实验是在 AutoDL 平台 ubuntu20.04 64 位操作系统环境下完成的，CPU 为 18 vCPU AMD EPYC 9754 128-Core Processor，GPU 为 RTX 4090D(24GB)。实验采用混合精度训练策略与迁移学习技术，所使用 CUDA 为 11.2，编程语言为 Python 3.8，深度学习框架为 TensorFlow 2.9.0。实验采用 Adam 优化器来更新参数，初始学习率设置为 0.001，损失函数为 categorical\_crossentropy（类别交叉熵），batch\_size 大小设置为 32，epochs 大小设置为 100，Dropout 值设置为 0.5，回调函数 patience 为 3，学习率衰减因子为 0.4，学习率最小值为 1e-6。

#### 5.1.2 评价指标

在本研究中，为了全面客观评估不同模型在番茄叶片病害识别任务中的表现，采用了多个常用的评估指标。包括准确率（accuracy）、精确率（precision）、召回率（recall）、F1 分数（f1\_score）、浮点运算次数（FLOPs）、参数量（params）以及推理时间（inference time）。前四个具体计算公式如下：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (5-1)$$

$$Precision = \frac{TP}{TP + FP} \quad (5-2)$$

$$Recall = \frac{TP}{TP + FN} \quad (5-3)$$

$$F1\ Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (5-4)$$

其中，TP 为真阳性（True Positive），TN 为真阴性（True Negative），FP 为假阳性（False Positive），FN 为假阴性（False Negative）。

### 5.2 对比实验结果与分析

为验证本研究的 DSC-EfficientNetB0 模型在番茄叶片病害识别任务中的有效性，对比实验特意采用了混合精度训练策略（通过半精度与单精度结合平衡速度和精度），

同时运用上迁移学习技术（借助预训练权重降低训练难度）。实验中选取的对比模型包含原版 EfficientNetB0（对应表 5-1 中 EfficientNetB0）以及 EfficientNetV2B0、MobileNetV3Small、ResNet50、DenseNet121 等 5 种主流深度学习模型。

从表 5-1 的综合评估指标对比结果来看，在迁移学习的运用下 DSC-EfficientNetB0 在准确率、精确率、召回率和 F1 分数等指标上均表现优异，准确率达到 99.78%，与原版 EfficientNetB0、MobileNetV3Small、DenseNet121 几乎持平，且均超 99.50% 的阈值。浮点运算次数和参数量分别为 0.7974G 和 4.26M 仅次于 MobileNetV3Small 的 0.1133G 和 1.54M，显著低于原版 EfficientNetB0、EfficientNetV2B0、ResNet50 和 DenseNet121，推理时间也保持在较低水平，其中模型参数量较未改进前原版 EfficientNetB0 减少 20.67%。

表 5-1 DSC-EfficientNetB0 与其他模型的比较

模型	准确率	精确率	召回率	F1 分数	FLOPs	参数量	推理时间
DSC-EfficientNetB0	99.78%	99.78%	99.78%	99.78%	0.7974G	4.26M	2.53s
EfficientNetB0	99.87%	99.87%	99.87%	99.87%	0.7893G	5.37M	2.49s
EfficientNetV2B0	99.51%	99.51%	99.51%	99.51%	1.4478G	7.24M	2.50s
MobileNetV3Small	99.91%	99.91%	99.91%	99.91%	0.1133G	1.54M	2.44s
ResNet50	99.56%	99.56%	99.56%	99.56%	7.7286G	25.70M	2.47s
DenseNet121	99.87%	99.87%	99.87%	99.87%	5.6710G	8.10M	2.55s

图 5-1 与图 5-2 表示 5 种深度学习模型与本研究改进的 DSC-EfficientNetB0 模型（对应图中的 DCA\_SDC\_CAN\_EfficientNetB0 的缩写）在验证集上的准确率与损失变化曲线。从验证集准确率变化曲线（Validation Accuracy Comparison）来看，DSC-EfficientNetB0 模型在训练到 20 次左右时，就能快速收敛，准确率迅速提升并很快稳定在较高水平，几乎没有什么大波动，这表明模型的训练稳定性和泛化能力都很好。相比之下，原版 EfficientNetB0（对应图 5-1 与图 5-2 图例中的 Original EfficientNetB0）虽然浮点运算次数与本研究模型持平，但在训练到 40 次左右准确率才收敛，而且收敛前的波动比本研究的模型大了很多；MobileNetV3Small 虽然在浮点运算次数和参数量上低于本研究模型，但同样到 40 次左右才收敛，波动也比较明显。至于 EfficientNetV2B0、ResNet50、DenseNet121，虽然它们在 20 次左右也能快速收敛，但浮点运算次数和参数量对比本研究模型则明显要高出许多。

再看验证集损失对比曲线（Validation Loss Comparison），这进一步佐证了上述结论。DSC-EfficientNetB0 的损失值下降速度特别快，在 20 次左右就收敛并最终稳定

在最低值，这表明模型在特征提取和分类方面具备更强的能力，还能够有效避免过拟合现象。相比之下，原版 EfficientNetB0 和 MobileNetV3Small，它们的损失在第 40 次左右才收敛，波动依旧很大；EfficientNetV2B0、ResNet50、DenseNet121 虽也能在 20 次左右让损失快速收敛，但浮点运算次数和参数量与本研究模型对比依旧过高。




图 5-1 验证集准确率变化曲线

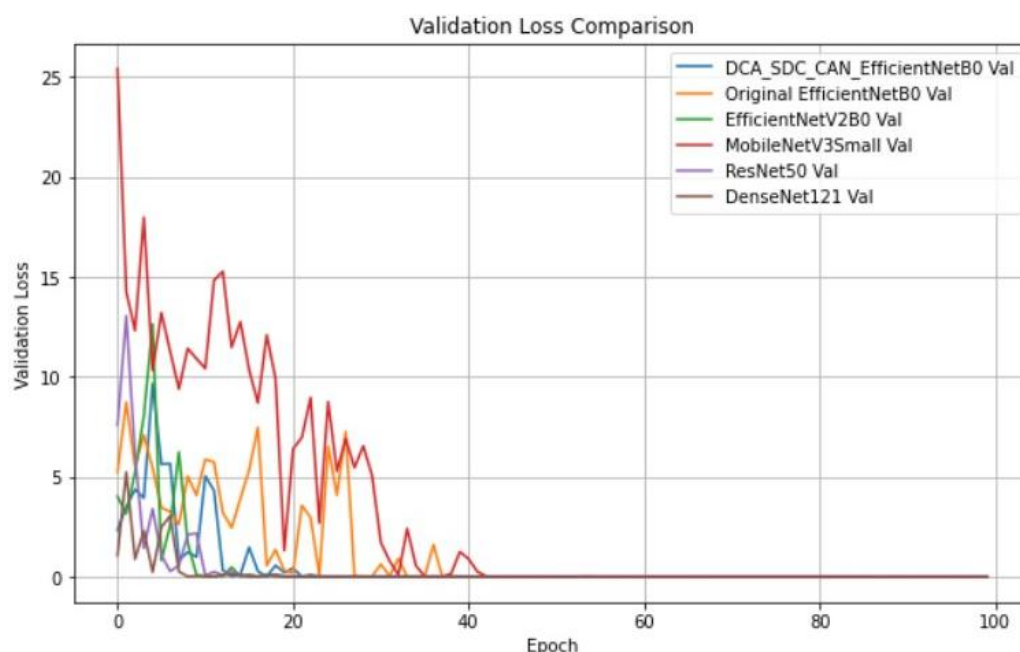


图 5-2 验证集损失变化曲线

为更直观地展示不同模型对各类番茄叶片病害的识别细节，接下来结合图 5-3 至图 5-8 的混淆矩阵热力图进一步分析，以全面评估各模型在番茄叶片病害识别任务中的分类表现。从混淆矩阵热力图可以看出，所有模型在大多数类别上的识别准确率都较高，预测结果主基本都集中在对角线上，这说明这些模型都能有效区分不同种类的



病害。

其中，图 5-3、图 5-4、图 5-5 分别对应 DSC\_EfficientNetB0、DenseNet121 和原版 EfficientNetB0（对应图 5-4 中 Original EfficientNetB0），这三个模型热力图上对角线颜色特别深，几乎所有类别的病害样本都能正确预测，误分类的样本少到可以忽略，充分体现了它们较强的特征提取和病害判别能力。图 5-6、图 5-7 分别对应 MobileNetV3Small 和 EfficientNetV2B0，这两个作为轻量化模型，整体分类效果也较好，但在“Late Blight”“Spider Mites”等少数类别上出现了个别误判，表明在处理复杂或相似病害时仍有提升空间。图 5-8 对应的 ResNet50 在“Bacterial Spot”“Early Blight”“Late Blight”“Spider Mites”“Target Spot”等类别上存在少量误分类情况，明显能看出在区分细粒度病害上存在不足。




图 5-3 DSC\_EfficientNetB0 混淆矩阵




图 5-4 DenseNet121 混淆矩阵

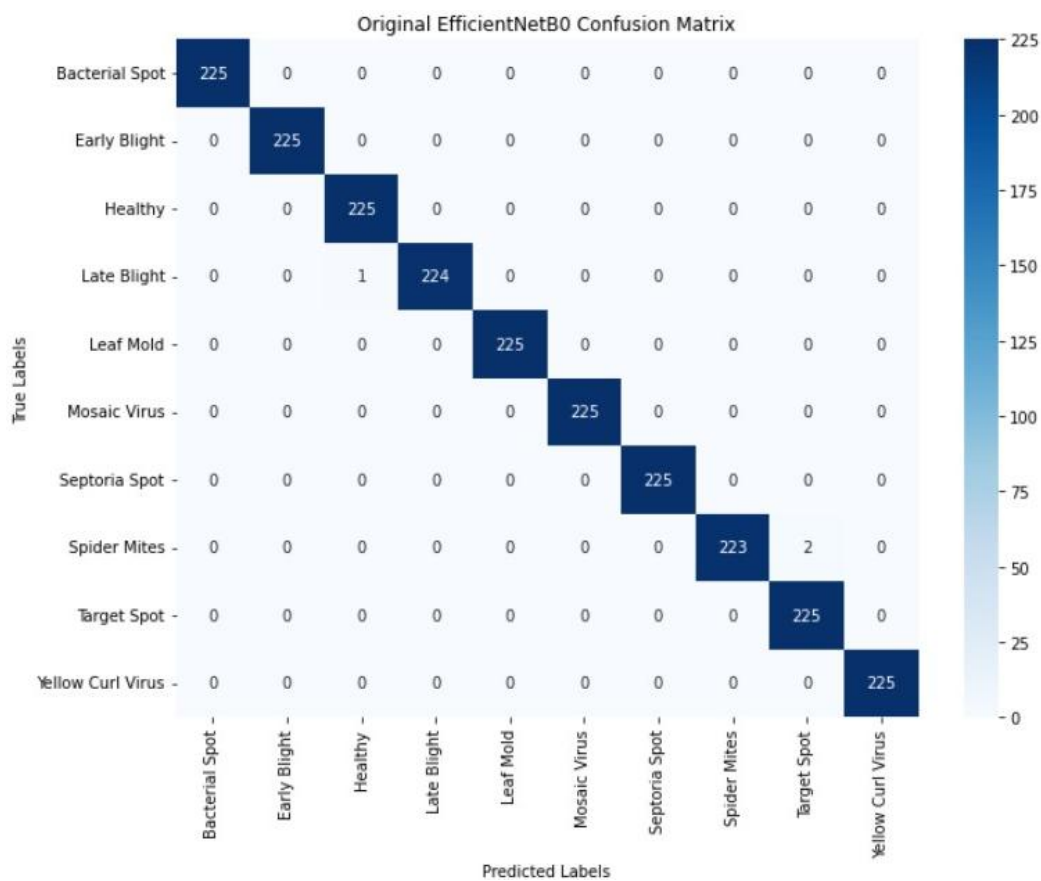


图 5-5 原版 EfficientNetB0 混淆矩阵

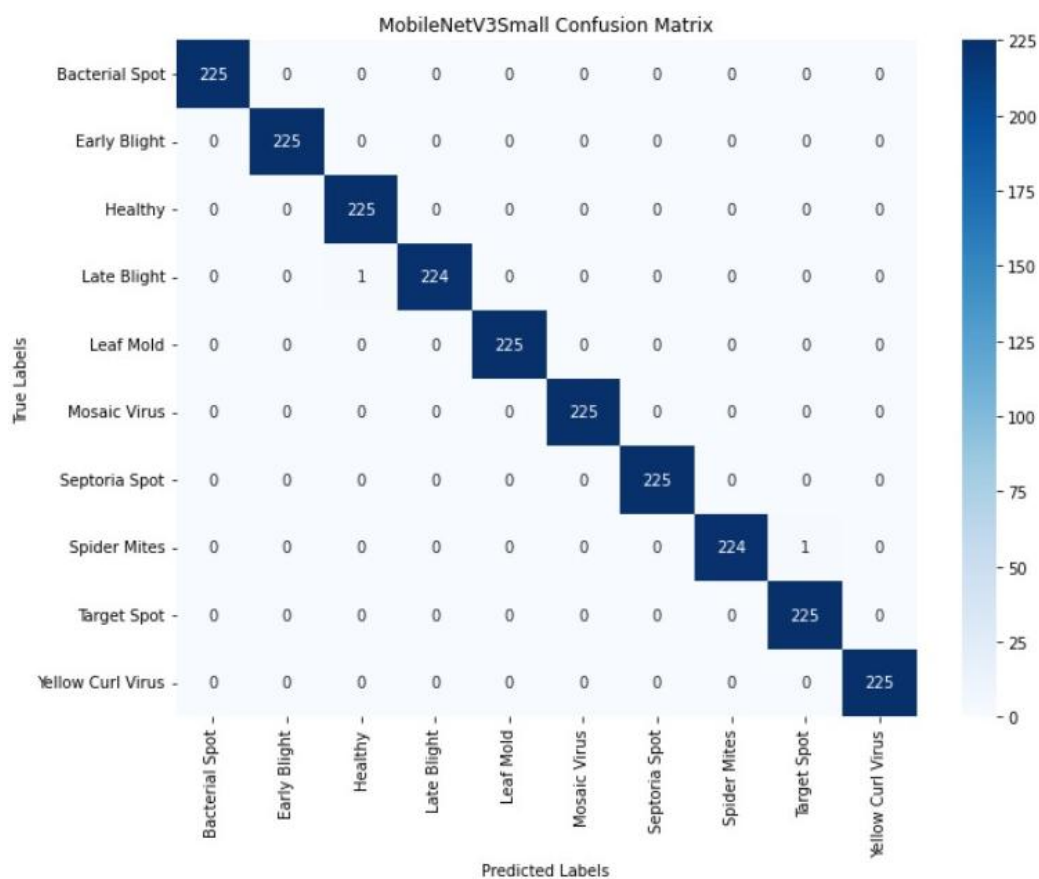


图 5-6 MobileNetV3Small 混淆矩阵




图 5-7 EfficientNetV2B0 混淆矩阵




图 5-8 ResNet50 混淆矩阵

综合分析对比实验结果，DSC\_EfficientNetB0 不仅在准确率、精确率、召回率和 F1 分数等核心指标上全部达到 99.78% 的高水准，与主流高精度模型持平甚至略好一点，同时明显优于部分轻量化模型。更重要的是，DSC-EfficientNetB0 在参数量和浮点运算次数上做到了有效压缩，参数量仅为 4.26M、浮点运算次数为 0.7974G，不仅远低于 ResNet50、DenseNet121 等主流模型，也优于原版 EfficientNetB0，这充分体现出本研究模型在田间便携设备这类资源受限场景下的高效性。

紧接着，从验证集准确率与损失变化曲线来看，DSC-EfficientNetB0 能够在训练迭代到 20 次以内时就能快速收敛，准确率迅速提升并保持稳定；损失值下降速度也快，最终还能降到最低。这两点直接说明本研究模型训练稳定性和泛化能力都特别好。对比之下，部分模型如原版 EfficientNetB0 和 MobileNetV3Small 收敛速度较慢，波动较大，EfficientNetV2B0、ResNet50、DenseNet121 虽然收敛较快，但计算资源消耗明显高于本研究模型。

最后，混淆矩阵热力图进一步验证了 DSC-EfficientNetB0 的分类能力。该模型在所有类别上的识别准确率均极高，误分类样本极少。

综合来看，DSC-EfficientNetB0 模型从核心评估指标、准确率与损失变化曲线，到混淆矩阵反映的分类细节，三方面都展现出优异性能，做到了高精度与高效性的兼

顾，充分证明了它在番茄叶片病害识别这一实际任务中的综合优势和落地应用价值。

### 5.3 消融实验结果与分析

为进一步验证 DCA（动态通道注意力）、SDC（可分离扩张卷积）、CAN（通道注意力）在 DSC-EfficientNetB0 模型中的有效性，本研究设计了 8 组模型的消融实验，实验依旧采用混合精度训练策略与迁移学习技术，分别去除或组合不同模块，比较其对模型性能的影响。消融实验结果如表 5-2 所示。

从表中数据可看出，由 DCA、SDC 和 CAN 三个模块集成的本研究模型在准确率、精确率、召回率和 F1 分数等指标上，全部达到 99.73%，FLOPs 为 0.7974G 和参数量 4.26M 保持在较低水平，推理时间也较短，体现了模型在高效性与高精度之间的最佳平衡。若同时去除三个模块，模型性能明显下降，准确率仅为 95.42%，精确率和召回率也大幅降低，模型参数量对比集成所有模块时还增加了 20%，这说明三个模块的加入对于提升模型的性能非常关键。

如果只去除 SDC 或 CAN 模块时，模型的各项指标均出现不同程度的下降，尤其是 FLOPs 和参数量有所增高，其次，精确率和召回率略有降低，说明 SDC 和 CAN 模块对于提升模型的计算成本和特征提取具有重要作用。仅保留 DCA 模块时，模型性能仍然较高，但略低于全部模块集成的情况，表明 DCA 模块对模型整体性能提升也有积极贡献。

综上，消融实验充分证明了 DCA、SDC 和 CAN 模块在 DSC-EfficientNetB0 模型中的有效性和必要性。

表 5-2 消融实验结果的比较

DCA	SDC	CAN	准确率	精确率	召回率	F1 分数	FLOPs	参数量	推理时间
√	√	√	99.73%	99.73%	99.73%	99.73%	0.7974G	4.26M	2.53s
√	√	×	99.78%	99.78%	99.78%	99.78%	0.7969G	4.25M	2.50s
√	×	√	99.82%	99.82%	99.82%	99.82%	0.9903G	7.45M	2.48s
√	×	×	99.73%	99.73%	99.73%	99.73%	0.7895G	5.40M	2.50s
×	√	√	99.73%	99.73%	99.73%	99.73%	0.7972G	4.23M	2.51s
×	√	×	99.60%	99.60%	99.60%	99.60%	0.7967G	4.23M	2.50s
×	×	√	98.22%	98.29%	98.22%	98.21%	0.9902G	7.43M	2.50s
×	×	×	95.42%	96.06%	95.42%	95.48%	0.7893G	5.38M	2.49s

图 5-9 至图 5-16 中展示的混淆矩阵通过直观的可视化方式展示了消融实验 8 组模型在各个病害类别任务上的分类性能对比情况。首先，从原始 EfficientNetB0（图 5-

16) 混淆矩阵可以看出，虽然整体分类能力较强，但在“Bacterial Spot”“Early Blight”“Healthy”“Spider Mites”“Target Spot”等类别上存在较多误分类，尤其是“Healthy”类别被误分为“Spider Mites”的数量较多，说明原始模型在部分相似类别区分上存在不足。

引入单一模块后，模型的分类表现有所提升。例如，加入 CAN 模块（图 5-15）后，“Bacterial Spot”“Healthy”等类别的识别准确率明显提高，但“Late Blight”“Target Spot”等类别仍有一定误判。加入 SDC 模块（图 5-14）后，模型在大多数类别上的分类准确率进一步提升，误分类数量减少，尤其是“Spider Mites”“Target Spot”等类别的识别效果更好。DCA 模块（图 5-12）同样带来了整体性能的提升，部分类别的误判现象得到缓解。

当组合两个模块时，模型的分类能力进一步增强，绝大多数类别的预测结果集中在对角线上，误分类样本极少。例如，DCA+SDC（图 5-10）、SDC+CAN（图 5-13）、DCA+CAN（图 5-11）等组合均能在“Early Blight”“Spider Mites”等易混类别上取得更好的区分效果。

最终，集成 DCA、SDC 和 CAN 三个模块的 DSC-EfficientNetB0（图 5-9）表现最为突出，所有类别的预测结果几乎全部集中在对角线上，误分类样本极少，说明模型对各类番茄叶片病害的判别能力最强，细粒度特征提取和类别区分能力达到最优。

综上，混淆矩阵图直观展示了各模块对模型性能的提升作用。单独引入 DCA、SDC 或 CAN 模块均能改善模型的分类表现，而多模块协同作用下，模型的识别准确率和鲁棒性达到最佳，进一步验证了消融实验表中各模块有效性分析的结论。

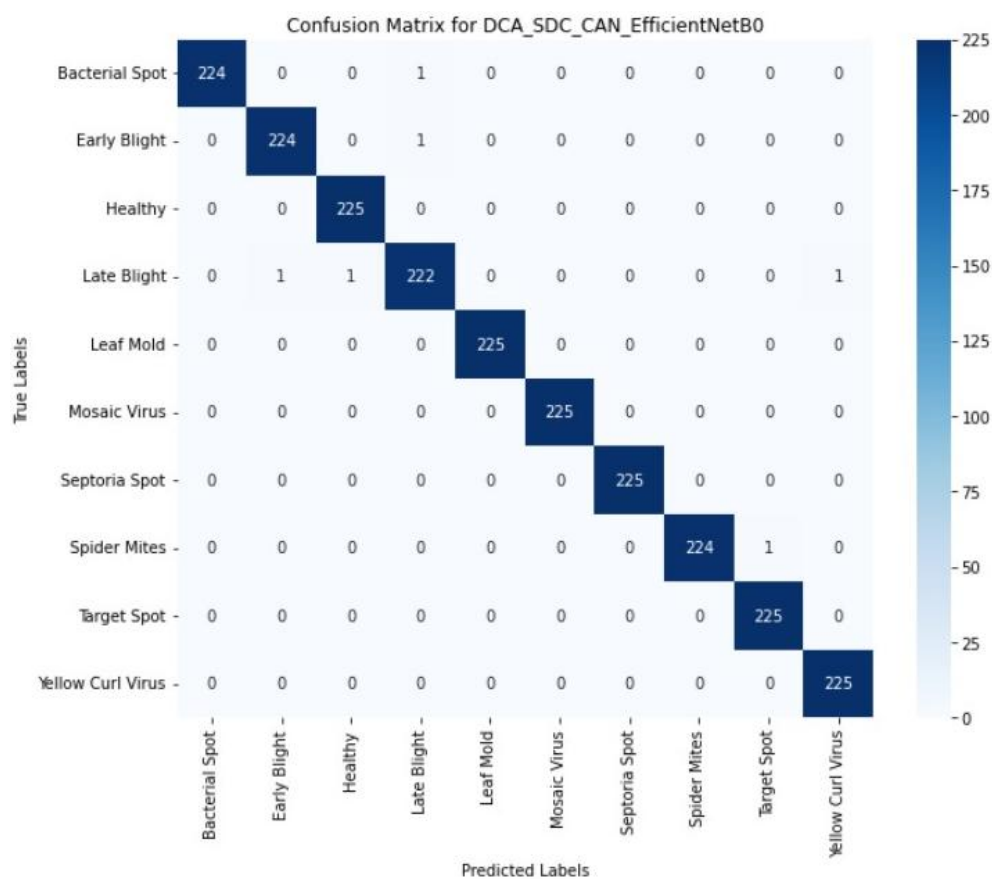


图 5-9 DCA\_SDC\_CAN\_EfficientNetB0 混淆矩阵




图 5-10 DCA\_SDC\_EfficientNetB0 混淆矩阵






图 5-11 DCA\_CAN\_EfficientNetB0 混淆矩阵




图 5-12 DCA\_EfficientNetB0 混淆矩阵






图 5-13 SDC\_CAN\_EfficientNetB0 混淆矩阵

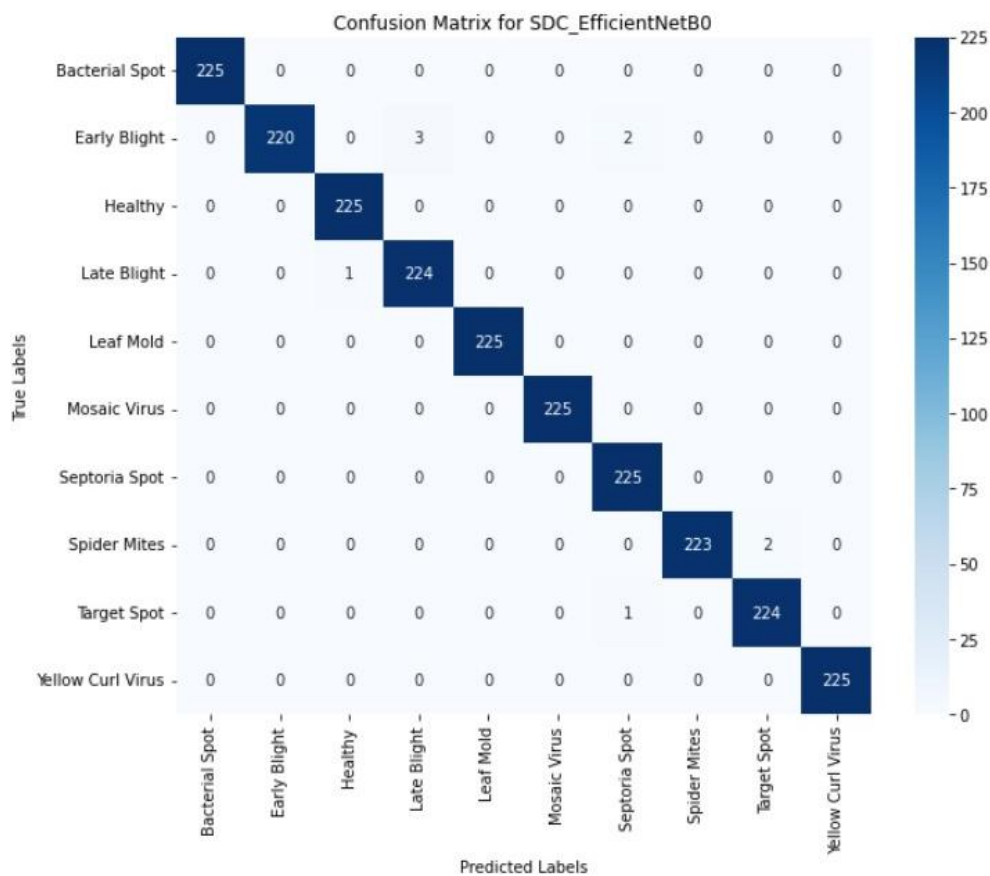


图 5-14 SDC\_EfficientNetB0 混淆矩阵




图 5-15 CAN\_EfficientNetB0 混淆矩阵



图 5-16 EfficientNetB0 混淆矩阵

## 6 总结与展望

### 6.1 总结

本研究针对番茄叶片病害识别在资源受限场景下的高精度识别的需求，基于 EfficientNetB0 网络，设计并验证 DSC-EfficientNetB0 模型——在主干网络后融合动态通道注意力（DCA）、可分离扩张卷积（SDC）和通道注意力（CAN）三类模块，并结合迁移学习与混合精度训练对番茄叶片病害数据集进行训练与验证，旨在兼顾高精度与低计算资源消耗，满足农业现场或边缘设备部署需求。

本文首先采用处理好的公开番茄叶片病害图像数据集，并在模型泛化上进行必要的图像增强扩充来解决样本不足和不平衡问题。在所用数据集与训练配置以及参数调优下，DSC-EfficientNetB0 在验证集上取得了 99.78% 的准确率（精确率、召回率和 F1 同值），FLOPs 为 0.7974G，参数量为 4.26M，推理时间为 2.53s。与原始 EfficientNetB0、EfficientNetV2B0、MobileNetV3Small、ResNet50、DenseNet121 等模型的对比实验、准确率和损失曲线、混淆矩阵以及消融实验均表明：

三模块协同能显著提升对细粒度病害特征的判别能力，减少同类间误判；在保持接近或等同分类性能的同时，模型在计算量与参数量上实现了较好的折中（远优于大型模型，略逊于极致轻量模型）；消融实验证明 DCA、SDC、CAN 各自均对性能有所贡献，三者联合时表现最佳，说明注意力机制与扩张可分离卷积在抓取局部细节与扩大感受野方面互为补充。

此外，通过验证集准确率和损失曲线看收敛速度、混淆矩阵看类别细节、三线表看指标对比等多维度评估，结果具备较强的可解释性，对实际部署参考价值大。本文提出并验证了在 EfficientNetB0 主干上集成动态通道注意力、可分离扩张卷积和通道注意力三类模块的有效方案，展示了在不用大幅增加计算负担，就能提升细粒度作物病害识别能力的方法论。所得到的模型对手机、农业便携终端等资源受限平台友好，明显具备在移动端或农业现场设备部署的潜力，为智能农业病害监测系统提供了可落地的模型候选。

### 6.2 展望

基于本研究的成果与当前学术发展趋势，未来工作可从以下几个方向进一步深化与拓展，以提高系统的实用性、鲁棒性与智能化水平：

- （1）构建更接近实际农业生产环境的多源数据集，覆盖不同地区、不同生长阶

段、不同相机与采集环境（包括田间、温室、实验室），并引入域自适应或无监督域泛化方法，以提升模型在实际生产环境中的迁移能力。

（2）多模态与高光谱融合，结合 RGB 图像以外的信息（近红外、高光谱、热红外或多视角 UAV 影像），利用多模态融合提升对早期病害和相似外观病害的判别能力。

## 参考文献

- [1] 邵润泽. 湖北省水产业发展路径研究[D]. 武汉轻工大学, 2024. DOI:10.27776/d.cnki.gwhgy.2024.000615.
- [2] 彭慧琳, 李东晖, 陈兆中, 等. 基于改进 GoogLeNet 的水稻苗期稻瘟病分级检测[J/OL]. 农业工程学报, 1-8[2025-06-06]. <http://kns.cnki.net/kcms/detail/11.2047.S.20250516.1624.049.html>.
- [3] 鲍义东, 李琳, 粟小妮. 深度卷积神经网络在番茄叶病害识别中的应用[J]. 福建电脑, 2025, 41(04):21-25. DOI:10.16707/j.cnki.fjpc.2025.04.004.
- [4] 马丽, 周巧黎, 赵丽亚, 等. 基于深度学习的番茄叶片病害分类识别研究[J]. 中国农机化学报, 2023, 44(07):187-193+206. DOI:10.13733/j.jcam.issn.2095-5553.2023.07.026.
- [5] 庄正飞. 基于卷积神经网络的番茄叶片病害识别研究[D]. 安徽农业大学, 2021. DOI:10.26919/d.cnki.gannu.2021.000356.
- [6] 王瑞鹏, 陈锋军, 朱学岩, 等. 采用改进的 EfficientNet 识别苹果叶片病害[J]. 农业工程学报, 2023, 39(18):201-210.
- [7] 牛学德, 高丙朋, 南新元, 等. 基于改进 DenseNet 卷积神经网络的番茄叶片病害检测[J]. 江苏农业学报, 2022, 38(01):129-134.
- [8] 周巧黎, 马丽, 曹丽英, 等. 基于改进轻量级卷积神经网络 MobileNetV3 的番茄叶片病害识别[J]. 智慧农业(中英文), 2022, 4(01):47-56.
- [9] 李云红, 张蕾涛, 谢蓉蓉, 等. 基于 AT-DenseNet 网络的番茄叶片病害识别方法[J]. 江苏农业科学, 2023, 51(21):209-217. DOI:10.15889/j.issn.1002-1302.2023.21.032.
- [10] 于锦龙, 于俊伟, 张自豪, 等. 基于改进 EfficientNet 的轻量化小麦不完善粒识别模型[J/OL]. 中国粮油学报, 1-15[2025-03-25]. <https://doi.org/10.20048/j.cnki.issn.1003-0174.000948>.
- [11] Marriam N ,Tahira N ,Ali J , et al.A robust deep learning approach for tomato plant leaf disease localization and classification[J].Scientific Reports,2022,12(1):18568-18568.
- [12] Mohamed B ,Badr H ,Khadija D , et al.Impact of Pretrained Deep Neural Networks for Tomato Leaf Disease Prediction[J].Journal of Electrical and Computer Engineering,2023,2023
- [13] Debnath A ,Hasan M M ,Raihan M , et al.A Smartphone-Based Detection System for Tomato Leaf Disease Using EfficientNetV2B2 and Its Explainability with Artificial Intelligence (AI) [J].Sensors,2023,23(21):
- [14] Gookyi N A D ,Wulnye A F ,Wilson M , et al.Enabling Intelligence on the Edge: Leveraging Edge Impulse to Deploy Multiple Deep Learning Models on Edge Devices for Tomato Leaf Disease Detection[J].AgriEngineering,2024,6(4):3563-3585.
- [15] Pratik B ,R. V A M .Recognize and classify illnesses on tomato leaves using Effi

cientNet's transfer learning approach with different size dataset[J].Signal, Image and Video Processing, 2024, 18(Suppl 1):731-746.

## 致 谢

写下致谢二字，这篇论文迎来了终章，我的大学生涯也即将结束，心中满是感慨与感激。回望大学时光，我度过了人生中最美的青春年华，在这里不仅学到了养活自己的专业技能，更重要的是从一个迷茫懵懂的少年成长为能够独当一面的青年。

首先，感谢我的毕业设计指导杨云老师。从毕设的论文选题、开题、实验规划和体系建立等阶段，杨老师一直给予了我很多宝贵指导和无私帮助。当遇到在实验上的重难点时，杨老师都会耐心地为我分析并提供具体可行的思路。后续，在毕设论文的整体架构以及各种格式要求等，也是他多次指导我，修改论文的不足之处，最终经过反复查缺补漏，我的毕业论文终于完成了。

人生路上，总会遇到一些良师和益友。感谢那些教导我如何做人，鼓励我勇敢去寻找人生意义的老师。同时，也感谢一直支持我的同龄朋友和同学，让我在人生路上不再孤单和迷茫。

最后，我还要感谢一直默默支持我的亲人。是他们的关心和付出，帮助我跨越了人生道路上的低谷，是他们的理解和包容，让我能够勇敢的走下去。

路漫漫其修远兮，吾将上下而求索。我会带着亲人、老师和朋友的祝福，在人生路上勇往直前。